# CDR 插件变体实验总表（2026-08-31）

本页汇总当前代码与实验设置下，两个跨域任务、四个 Backbone 及全部已完成插件变体的结果。所有数值均来自本轮重新运行的完整日志，不沿用此前论文表格中的 Backbone 数值。

## 统计口径

- 每个结果单元格统一写作 **R@20 / N@20**，第二行括号内为相对同一行 Pure Backbone 的 **ΔR / ΔN**。
- 插件变体仅从 `pseudo_loss_weight ≠ 0` 的已完成实验中选择：按测试集 R@20 最高确定展示配置；若并列，则保留搜索顺序中先出现的配置。
- “严格双升”表示 R@20 与 N@20 均高于 Pure Backbone；“均不下降”允许其中一个或两个指标持平。
- 第一阶段的置信度校准属于诊断实验，不直接训练推荐模型，因此不单列为性能变体。

## 变体说明

| 变体 | 伪交互构造 | 训练方式 |
| --- | --- | --- |
| Pure Backbone | 不使用伪交互 | 当前代码下重新运行的基线 |
| 原始物品级 G | 使用原始物品级语义到协同空间映射召回 Top-K | 固定伪交互集合 + pseudo BPR |
| 用户级 G | 使用用户级语义到协同空间映射召回 Top-K | 固定伪交互集合 + pseudo BPR |
| Direct Semantic | 直接使用用户兴趣语义与物品语义相似度召回 Top-K | 固定伪交互集合 + pseudo BPR |
| Popularity | 按目标域训练交互频次排序，所有冷用户共享全局热门 Top-5 | 固定伪交互集合 + pseudo BPR |
| 阶段 2 v1 | 固定候选 + c_sem / c_ov 校准后的静态置信度 | 置信度加权 pseudo BPR |
| 阶段 2 v2 | 候选池排序后保留高置信用户与物品 | 置信度加权 + 用户表示残差注入 |
| 阶段 2 v2.1（Adaptive） | 沿用固定置信候选，并联合调节直接伪监督与用户残差 | 搜索联合伪监督缩放系数与残差注入强度 |
| 阶段 3（新版 v3） | 以阶段 2 v2.1 的固定候选、直接伪监督与共享残差为起点，加入 EMA 模型证据和重叠用户动态校准 | 从全物品空间受控扩展；语义 Top-5 永久保留，并同步更新直接伪监督、残差候选与用户门控 |
| 三分类可信伪监督（TriClass） | 合并 Direct Semantic、重新训练的用户级 G 和 Popularity 候选，使用四项证据区分 Hit / Near / Unsupported | 静态三分类概率加权 pseudo BPR；不使用残差打分、EMA 或候选扩展 |

## 阶段 2 系列详细实现

阶段 2 v1、v2 和 v2.1 均使用同一份用户级 G 伪交互候选及静态置信度缓存，因此三者的主要差异在于候选筛选、训练目标和推理时的使用方式，而不是重新生成一套 LLM 语义。

### 共同的静态置信度基础

1. **固定候选池**：用户级 G 为每个用户保存 Top-100 目标物品；训练插件默认使用官方 Top-5，v2/v2.1 可从 Top-100 中进一步筛选。
2. **语义证据 c_sem**：将初始伪交互召回分数在每个用户内部归一化，表示候选与用户目标域兴趣模式的匹配强度。
3. **重叠证据 c_ov**：先在源域交互图上训练两层 LightGCN，再为每个查询用户寻找 20 个源域相似的重叠用户；候选物品与这些邻居真实目标域历史的最大物品相似度，经邻居权重聚合后作为行为支持度。
4. **重叠用户校准**：重叠用户只以源域交互生成伪候选，目标域训练交互仅作为命中标签。用户按 60% / 20% / 20% 划分，使用带正权约束的二特征线性校准器融合 c_sem 与 c_ov，得到静态可靠度 rho_static。
5. **迁移到冷用户**：校准器固定后，同样作用于冷用户候选，生成 cold_static_confidence.npz，供所有 Backbone 共享。

### 阶段 2 v1：固定候选的置信度加权训练

**保持用户级 $G$ 生成的伪交互集合不变，为每个伪交互估计一个静态可信度，再用该可信度加权 Backbone 的伪交互 BPR 损失。**

- 候选集合始终保持不变。每个 mini-batch 从官方 Top-5 伪正样本中抽样，负物品不能出现在该用户的伪正集合或已知目标正样本中。
- 每个伪样本采用 `rho_static^p` 作为权重，训练目标为按权重和归一化的 BPR 损失；总损失是在 Backbone 原损失上增加 pseudo_loss_weight × L_pseudo。
- 实验可选择 semantic、overlap 或 combined 置信度来源，并搜索置信度幂次 p。
- v1 不更新候选集合，也不修改推理打分；伪监督只通过训练损失影响 Backbone 表示。
- 主要实现：`grounded_static_confidence.py`、`grounded_confidence_pseudo.py` 及四个 Backbone wrapper。

阶段 2 v1 的核心思想是：

> **保持用户级 $G$ 生成的伪交互集合不变，为每个伪交互估计一个静态可信度，再用该可信度强权 Backbone 的伪交互 BPR 损失。**

它解决的是"伪交互不能一视同仁"的问题，而不是重新生成或动态扩展伪交互。

**整体流程**

```
源域交互
  ↓
LLM 提取源域兴趣并推断目标域兴趣
  ↓
用户级 G 映射到目标域协同空间
  ↓
召回固定的目标域伪交互候选
  ↓
计算语义证据 c_sem 和重叠用户证据 c_ov
  ↓
用重叠用户真实交互校准置信度 p_static
  ↓
固定 Top-5 伪交互 + 置信度加权 BPR
  ↓
联合训练 EMCDR / UniCDR / CD-CDR / CDRIB
```

### 1. 固定伪交互候选

阶段 2 v1 使用的是此前由**用户级 $G$ 生成的伪交互缓存**。

对于用户 $u$，用户级 $G$ 将其目标域兴趣语义表示映射到目标域协同表示空间，再与目标域物品表示计算召回分数：

$$s_{uv}^{G} = G(\mathbf{q}_u)^{\top}\mathbf{e}_v^{t}.$$

按照分数排序得到：

$$\tilde{\mathcal{I}}_u = \mathrm{TopK}_{v \in \mathcal{I}_t} s_{uv}^{G}.$$

缓存中可以保留 Top-100 候选，以便分析和后续方法使用；但是阶段 2 v1 的训练只使用原始排序最前面的 Top-5：

$$\mathcal{I}_u^{(5)} = \{i_{u,1}, \dots, i_{u,5}\}.$$

这里有两个关键点：

- 候选集合在 Backbone 训练过程中不更新。
- v1 不会按照置信度重新排序 Top-100，也不会把后面的物品换进 Top-5。

因此，v1 中的"固定候选"指的就是用户级 $G$ 原始召回的 Top-5。

### 2. 语义证据 $c^{\mathrm{sem}}$

对每个候选伪交互 $(u, i)$，首先取用户级 $G$ 召回时的原始分数，并在同一用户的候选物品之间进行归一化：

$$c_{ui}^{\mathrm{sem}} = \frac{s_{ui}^{G} - \min_j s_{uj}^{G}}{\max_j s_{uj}^{G} - \min_j s_{uj}^{G} + \epsilon}.$$

它表达的是：

> 候选物品 $i$ 与用户推导出的目标域兴趣模式有多匹配。

虽然代码中将为 `semantic_evidence`，但它不是简单的原始文本 embedding 余弦相似度，而是**经过用户级 $G$ 映射后得到的视角召回证据。**

### 3. 重叠用户证据 $c^{\mathrm{ov}}$

只有语义匹配还不够，所以 v1 进一步利用重叠用户的真实跨域行为提供协同证据。

#### 3.1 训练源域 LightGCN

在源域交互图上训练一个两层 LightGCN，得到所有用户的源域协同表示：

$$\mathbf{h}_u^{s}.$$

这个 LightGCN 只用于寻找行为相似的用户，不会替代 EMCDR、UniCDR 等 Backbone。

#### 3.2 寻找相似重叠用户

对于查询用户 $u$，从重叠用户中寻找源域表示最相似的 $M$ 个用户：

$$\mathcal{N}_u^{o} = \mathrm{TopM}_{o \in \mathcal{U}_o} \cos(\mathbf{h}_u^{s}, \mathbf{h}_o^{s}).$$

当前实现中通常取 $M = 20$。相似度经过带温度的 softmax：

$$\alpha_{uo} = \frac{\exp(\cos(\mathbf{h}_u^{s}, \mathbf{h}_o^{s})/\tau)}{\sum_{o' \in \mathcal{N}_u^{o}} \exp(\cos(\mathbf{h}_u^{s}, \mathbf{h}_{o'}^{s})/\tau)}.$$

#### 3.3 检查候选是否得到目标域行为支持

对于候选目标物品 $i$，检查相似重叠用户 $o$ 在目标域真实交互过的物品中，是否存在与 $i$ 相近的物品：

$$r_{oi} = \max_{j \in \mathcal{I}_o^{t}} \cos(\mathbf{e}_i^{t}, \mathbf{e}_j^{t}).$$

再按照邻居权重聚合：

$$c_{ui}^{\mathrm{ov}} = \sum_{o \in \mathcal{N}_u^{o}} \alpha_{uo} r_{oi}.$$

直观来说，$c_{ui}^{\mathrm{ov}}$ 回答的是：

> 与用户 $u$ 在源域兴趣相似的重叠用户，是否真的在目标域喜欢过与候选 $i$ 类似的物品？

### 4. 用重叠用户校准置信度

对于重叠用户，我们知道其目标域训练交互。因此可以判断伪候选是否命中真实交互：

$$y_{ui} = \mathbf{1}[i \in \mathcal{I}_u^{t}].$$

需要注意，重叠用户的目标域交互：

- 不参与 LLM 兴趣推断；
- 不参与初始候选生成；
- 只用于构造 $c^{\mathrm{ov}}$、训练置信度校准器和评估伪交互质量。

重叠用户按照固定随机种子划分为训练、验证和测试部分，比例为 $60\%/20\%/20\%$。

校准器输入两个特征：

$$\mathbf{x}_{ui} = [c_{ui}^{\mathrm{sem}}, c_{ui}^{\mathrm{ov}}].$$

标准化后使用低容量线性校准器：

$$p_{ui}^{\mathrm{static}} = \sigma\left(w_{\mathrm{sem}} c_{ui}^{\mathrm{sem}} + w_{\mathrm{ov}} c_{ui}^{\mathrm{ov}} + b\right).$$

其中 $w_{\mathrm{sem}}$ 和 $w_{\mathrm{ov}}$ 被约束为非负，防止模型学出"证据越强、置信度反而越低"的关系。

由于真实命中非常稀疏，训练时使用带正负权重的 BCE。训练完成后，同一个固定校准器会应用到冷启动用户，得到每个冷用户伪交互的静态置信度。

具体实现位于 🔷 `grounded_static_confidence.py`。

### 5. 置信度加权伪交互训练

对于固定伪正样本 $(u, i^{+})$，从以下物品之外采样负样本 $i^{-}$：

- 用户当前的伪正样本集合；
- 用户已知的目标域正交互集合。

Backbone 根据自己的用户和物品表示计算 BPR 损失：

$$\ell_{ui}^{\mathrm{pseudo}} = -\log\sigma\left(s_\theta(u, i^{+}) - s_\theta(u, i^{-})\right).$$

伪交互权重为：

$$w_{ui} = \max\{p_{ui}^{\mathrm{static}}, \epsilon\}^{p},$$

其中 $p$ 控制置信度的区分强度：

- $p < 1$：减弱高低置信度之间的差距；
- $p = 1$：直接使用校准置信度；
- $p > 1$：更强调高置信度样本。

最终采用归一化加权损失：

$$\mathcal{L}_{\mathrm{pseudo}} = \frac{\sum_{(u,i) \in \mathcal{D}} w_{ui} \ell_{ui}^{\mathrm{pseudo}}}{\sum_{(u,i) \in \mathcal{D}} w_{ui}}.$$

然后与原始 Backbone 损失联合训练：

$$\mathcal{L} = \mathcal{L}_{\mathrm{backbone}} + \lambda_{\mathrm{pseudo}} \mathcal{L}_{\mathrm{pseudo}}.$$

其中：

- $\lambda_{\mathrm{pseudo}}$ 控制插件整体影响；
- $p$ 控制伪交互内部的置信度差异；
- `confidence_source` 可以选择 `semantic`、`overlap` 或 `combined`。

相关实现位于 🔷 `grounded_confidence_pseudo.py`。

### 6. 如何接入四个 Backbone

阶段 2 v1 不改变各 Backbone 的核心结构，只增加一项辅助伪交互损失。

以 EMCDR 为例：

1. 用 EMCDR 原本的映射网络生成冷用户目标域表示；
2. 用 EMCDR 原本的目标物品表示计算伪正、伪负分数；
3. 计算置信度加权 BPR；
4. 加到 EMCDR 原始训练目标中。

实现入口是 🔷 `emcdr_grounded_confidence_pseudo.py`。

UniCDR、CD-CDR 和 CDRIB 也是同样原则：**候选和置信度共享，但伪交互分数由各自 Backbone 的表示计算。**

### 7. 推理阶段

v1 在推理时不直接使用伪交互置信度，也不修改最终打分公式：

$$s_{\mathrm{final}}(u, i) = s_{\mathrm{backbone}}(u, i).$$

所以它的性能变化完全来自训练期间伪交互监督对 Backbone 表示的影响，不存在额外的推理分数融合。

### 8. v1 的能力边界

阶段 2 v1 能做到：

- 区分固定伪交互中的高可信和低可信样本；
- 降低低质量伪交互对 Backbone 的噪声；
- 让不同 Backbone 共享同一套候选和置信度。

但它做不到：

- 修复初始 Top-5 中不存在真实物品的问题；
- 根据训练状态更新置信度；
- 扩展新的候选物品；
- 在推理阶段直接纠正 Backbone 排名。

一句话概括：

> **阶段 2 v1 是"用户级 $G$ 的固定 Top-5 候选 + 气泡双证据置信度 + 加权伪交互 BPR"，本质上是一个训练期的可信样本加权插件。**

### 阶段 2 v2：高置信筛选与独立残差打分

它继续使用阶段 1 得到的静态置信度，但不再像 v1 那样直接修改 Backbone，而是：**冻结已经训练好的 Backbone，只为少量高置信度冷用户学习一个独立的残差表示，并在推理时将残差分数加到 Backbone 分数上。宁可只帮助少量可靠用户，也不让不可靠伪交互破坏整个 Backbone。**

- 先按 combined confidence 对 Top-100 候选重新排序，以每个用户最高候选的置信度作为用户可靠度，只保留最高 5% 或 10% 的用户，并为每个保留用户选 Top-1 伪正物品。
- Backbone 先按原流程训练；随后进入独立残差阶段，冻结整个 Backbone 和归一化后的目标物品表示，只训练一个从零初始化的、按用户 ID 独立存储的残差向量。
- 残差向量使用置信度加权 BPR 学习。采样概率也随候选置信度提高，从而让可靠伪交互被更频繁使用。
- 冷用户推理分数为 base_score + beta × gate_u × scale_u × residual_score。其中 gate_u 对未保留用户为 0，对保留用户由置信度归一化得到；scale_u 对齐基础分数与残差分数的标准差并限制最大缩放。
- 主要搜索参数是保留用户比例与 beta。该版本的残差是自由的用户 ID 参数，用户之间不共享映射结构。
- 主要实现：`grounded_residual_pseudo.py` 及四个 Backbone wrapper。

阶段 2 v2 在代码中对应 Grounded Residual Pseudo。它继续使用阶段 1 得到的静态置信度，但不再像 v1 那样直接修改 Backbone，而是：

> 冻结已经训练好的 Backbone，只为少量高置信度冷用户学习一个独立的残差表示，并在推理时将残差分数加到 Backbone 分数上。

**整体流程**

```
训练纯 Backbone
  ↓
读取用户级 G 生成的 Top-100 候选及静态置信度
  ↓
按置信度重新排序候选
  ↓
只保留置信度最高的一小部分冷用户
  ↓
每个保留用户选置信度最高的 Top-1 物品
  ↓
冻结 Backbone，只学习用户残差向量
  ↓
推理时：Backbone 分数 + 置信度门控的残差分数
```

**1. 置信度重排候选**

v2 仍然使用阶段 1 的组合置信度：

$$\rho_{ui}^{static} = f_{cal}\left(c_{ui}^{sem}, c_{ui}^{cf}\right).$$

但与 v1 不同，v2 不使用用户级 $G$ 原始排序的 Top-5，而是对每个用户的候选池按照 $\rho_{ui}^{static}$ 重新排序：

$$\pi_u = \operatorname{argsort}_{i \in \mathcal{C}_u} \rho_{ui}^{static}.$$

当前设置的候选池大小为：

$$|\mathcal{C}_u| = 100.$$

因此，原始召回排在后面、但经过双证据校准后置信度更高的物品，可以被重新排到前面。

**2. 筛选高置信度用户**

对于每个冷启动用户，取其最高候选置信度作为用户级可靠性：

$$q_u = \max_{i \in \mathcal{C}_u} \rho_{ui}^{static}.$$

然后只保留 $q_u$ 最高的前 $\eta$ 比例冷用户：

$$\mathcal{U}_{keep} = \operatorname{Top}_{\eta}\{q_u \mid u \in \mathcal{U}_c\}.$$

当前实验搜索：

$$\eta \in \{0.05, 0.10\}.$$

也就是只对置信度最高的 $5\%$ 或 $10\%$ 冷用户使用插件。其余用户保持纯 Backbone 结果，避免低质量伪监督造成普遍性破坏。

**3. 构造残差伪交互**

对每个保留用户，当前只选择重新排序后的 Top-1 物品：

$$i_u^+ = \arg\max_{i \in \mathcal{C}_u} \rho_{ui}^{static}.$$

因此当前配置是：

```yaml
residual_candidate_pool_size: 100
residual_top_k: 1
residual_retained_user_fraction: [0.05, 0.10]
```

正样本对为：

$$\widetilde{\mathcal{D}}_{res} = \{(u, i_u^+) \mid u \in \mathcal{U}_{keep}\}.$$

负物品从用户的伪正集合及已知目标域正交互之外采样。

**4. 冻结 Backbone**

EMCDR、UniCDR、CD-CDR 或 CDRIB 首先按照原始流程完成训练。进入额外的残差训练阶段后：

- Backbone 的全部参数被冻结；
- Backbone 的目标物品表示被冻结并归一化；
- 只训练一个独立的用户残差向量 $\mathbf{r}_u$。

每个冷用户都有一个自由残差向量，初始化为零：

$$\mathbf{r}_u^{(0)} = \mathbf{0}.$$

它不是从 Backbone 用户表示经过网络计算出来的，而是一个独立的、可训练的用户 embedding。这也是 v2 与 v2.1 的重要区别。

实现见 grounded_residual_pseudo.py。

**5. 残差分支训练**

使用冻结的目标物品表示 $\tilde{\mathbf{e}}_i^t$，计算残差分数：

$$s_{ui}^{res} = \mathbf{r}_u^\top \tilde{\mathbf{e}}_i^t.$$

残差 BPR 损失为：

$$\ell_{ui}^{res} = -\log \sigma\left(s_{ui^+}^{res} - s_{ui^-}^{res}\right).$$

再使用静态置信度加权：

$$\mathcal{L}_{res} = \frac{1}{|\mathcal{B}|} \sum_{(u,i^+,i^-) \in \mathcal{B}} \rho_{ui^+}^{static} \ell_{ui}^{res} + \lambda_{L2} \|\mathbf{r}_u\|_2^2.$$

当前还会按照置信度进行采样：

$$P(u,i) \propto \left(\rho_{ui}^{static}\right)^\gamma,$$

其中默认 $\gamma = 1$。因此高置信度伪交互既更容易被抽到，在损失中也有更高权重。

**6. 推理分数融合**

对于冷启动用户，最终分数为：

$$s_{ui} = s_{ui}^{base} + \beta g_u a_u s_{ui}^{res}.$$

其中：

- $s_{ui}^{base}$：冻结 Backbone 的原始分数；
- $\beta$：残差分支的总体强度；
- $g_u$：用户置信度门控；
- $a_u$：对齐 Backbone 分数与残差分数量级的缩放系数。

用户门控为：

$$g_u = \begin{cases} q_u / \max_v q_v, & u \in \mathcal{U}_{keep}, \\ 0, & \text{otherwise}. \end{cases}$$

当前搜索的融合强度为：

$$\beta \in \{0.05, 0.10, 0.20\}.$$

未被保留的用户 $g_u = 0$，所以其预测结果与纯 Backbone 完全一致。

**与 v1 的区别**

| 设计 | 阶段 2 v1 | 阶段 2 v2 |
|---|---|---|
| 候选 | 原始 Top-5 | Top-100 按置信度重排后取 Top-1 |
| 用户范围 | 所有冷用户 | 最高置信度的 5%/10% |
| Backbone | 与伪损失联合训练 | 完全冻结 |
| 新参数 | 无独立分支 | 每个用户一个自由残差向量 |
| 推理 | 仅使用 Backbone | Backbone + 残差分数 |
| 风险 | 噪声可能破坏 Backbone | 主干不受影响，但覆盖用户较少 |

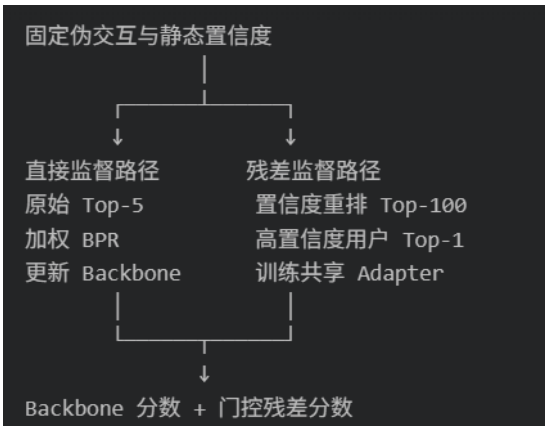
所以，v2 的设计目标是：**宁可只帮助少量可靠用户，也不让不可靠伪交互破坏整个 Backbone。**

它的主要局限是每个用户的残差向量彼此独立、不能共享知识，而且未被筛选的用户完全得不到帮助。这正是后续 v2.1 使用共享用户条件 $\downarrow$ 3器的原因。

1:27 PM

## 阶段 2 v2.1（Adaptive）：共享残差适配器与双路径联合

**把 v1 和 v2 的两条路径合并,一条路径直接用伪交互联合训练 Backbone；另一条路径通过共享适配器生成残差分数，并根据用户置信度自适应地融合到最终排序中。**




完整训练目标为：

$$\mathcal{L} = \mathcal{L}_{\text{base}} + j\lambda_{\text{pseudo}}\mathcal{L}_{\text{direct}} + \mathbf{1}[\beta > 0]\lambda_{\text{res}}\mathcal{L}_{\text{res}}.$$

- 保留 v1 的直接伪监督路径，同时保留 v2 的高置信残差思想；两条路径可以按 Backbone 和数据方向独立调节。
- 不再为每个用户学习自由残差向量，而是将 Backbone 的源域用户表示输入共享适配器：LayerNorm → Linear → ReLU → Linear。最后一层零初始化，因此残差分支从不改变基础打分的状态平滑开始。
- 残差 BPR 使用同一批高置信 Top-1 候选。源用户表示和目标物品表示在该损失中 detach，只让共享适配器接收残差梯度；Backbone 仍由自身损失和直接伪监督路径训练。
- 推理时使用所有冷用户的置信度百分位构造软门控，而不是 v2 的硬保留门控。门控以最高 5% 附近为中心，并用温度 0.025 的 sigmoid 平滑过渡。
- 总体可理解为 L_backbone + j × lambda_pseudo × L_pseudo + L_residual；推理为 base_score + beta × soft_gate_u × scale_u × residual_score。
- j 控制 v1 直接伪监督强度，beta 控制残差分数注入强度。当前 12 组搜索如下：

| j | 搜索的 beta | 含义 |
|---|---|---|
| 1.00 | 0、0.005、0.01、0.03 | 完整保留直接伪监督，从 v1 边界逐步加入残差 |
| 0.50 | 0.005、0.01、0.03 | 降低直接伪监督，保留中等联合约束 |
| 0.25 | 0.01、0.03 | 弱直接伪监督，以残差路径为主 |
| 0.00 | 0.01、0.03、0.05 | 关闭直接伪监督，只保留 Backbone 与残差路径 |

- 主要实现：`grounded_adaptive_pseudo.py` 及四个 Backbone wrapper。

## 阶段 3（新版 v3）：在 v2.1 上进行可信扩展

- **起点固定为 v2.1 最优点**：每个“任务 × Backbone”先采用该行已经选出的 `adaptive_setting`，保留 v2.1 的直接伪监督、共享残差适配器及软用户门控，不再从裸 Backbone 单独构造阶段 3。
- **EMA 提议**：训练中的学生参数以 0.995 衰减更新 EMA 教师；教师从全目标物品空间为冷用户提出新候选。
- **同分布动态校准**：校准器在重叠用户上同时观察静态语义候选与 EMA 模型 Top 候选，使用 `c_sem`、`c_ov`、`c_model` 三类证据学习置信度，避免旧版只用静态候选训练后直接外推到模型 Top-1。
- **锚定与受控接收**：原始语义 Top-5 永久保留。新候选还必须同时通过校准阈值、v2.1 用户门控、相对锚点置信度和全局每轮接收配额；最多扩展 3 轮，每个用户最多保留 8 个直接伪正样本。
- **双路径同步**：每轮扩展后同时重建直接 pseudo BPR 的样本权重、共享残差分支的高置信候选，以及推理时的软用户门控。
- **单参数搜索**：`v3_setting ∈ {strict, balanced, broad}` 联动控制最小用户门控、每轮最大接收比例、候选分位阈值和锚点要求；其余 Backbone 与 v2.1 参数保持固定。

- 主要实现：`grounded_expandable_pseudo.py` 及 EMCDR、UniCDR、CDRIB、CD-CDR Normal 四个 wrapper。

**V3 的核心思路**

V3 是在阶段 2 v2.1（Adaptive）基础上加入"动态置信度校准 + EMA 候选扩展"。它不再把初始伪交互集合固定到训练结束，而是在训练过程中反复执行：

$$\text{EMA 提议新物品} \rightarrow \text{三种证据评估} \rightarrow \text{校准置信度} \rightarrow \text{筛选并扩展伪交互}$$

**1. 初始伪交互**

首先沿用用户级 $G$ 生成的伪交互集合。

1. LLM 根据用户的源域交互推断目标域兴趣。
2. 将目标域兴趣编码成语义表示 $q_u$。
3. 用户级映射函数 $G$ 将 $q_u$ 映射到目标域协同空间。
4. 与目标域物品嵌入计算相似度，召回初始 Top-5：

$$\widetilde{\mathcal{I}}_u^{(0)} = \mathrm{TopK}_{i \in \mathcal{I}^t} \left\langle G(q_u), e_i^t \right\rangle .$$

这五个物品是 V3 的初始可信锚点，后续不会被删除。V3 只在它们的基础上增加新物品。

**2. 继承 v2.1 的两条训练路径**

V3 不是独立替换 backbone，而是继承 v2.1 的训练结构。

第一条是把伪交互 BPR 损失加入 backbone：

$$\mathcal{L} = \mathcal{L}_{\text{backbone}} + j\lambda_{\text{pseudo}}\mathcal{L}_{\text{pseudo}} + \mathcal{L}_{\text{residual}}.$$

其中 $j$ 控制伪交互对 backbone 参数的影响，$\lambda_{\text{pseudo}}$ 是整体伪监督权重。

第二条是残差 Adapter。它学习伪交互能够提供、但 backbone 尚未学到的补充信号。推理时：

$$s_{ui} = s_{ui}^{\text{base}} + \beta g_u a_u s_{ui}^{\text{res}}.$$

这里 $\beta$ 是残差强度，$g_u$ 是用户可信门控，$a_u$ 用于对齐 backbone 与残差分数的尺度。

**3. EMA 教师生成新候选**

从第 10 个 epoch 开始，V3 建立 backbone 的 EMA 教师：

$$\theta_{\text{EMA}} \leftarrow 0.995\theta_{\text{EMA}} + 0.005\theta_{\text{student}}.$$

EMA 教师不参与梯度更新，只负责给冷启动用户对目标域全物品打分并提出新候选。

默认在 epoch 10、20、30 分别刷新一次，最多三轮。每轮每个用户最多提出一个新物品，因此初始 Top-5 最多扩展为 Top-8。

**4. 三种置信度证据**

对候选伪交互 $(u, i)$，V3 计算三个证据。

$$\mathbf{c}_{ui} = [c_{ui}^{\text{sem}}, c_{ui}^{\text{ov}}, c_{ui}^{\text{model}}].$$

**语义证据 $c^{\text{sem}}$**

衡量目标物品 $i$ 与用户目标域兴趣 $q_u$ 的匹配程度：

$$c_{ui}^{\text{sem}} \propto \left\langle G(q_u), e_i^t \right\rangle .$$

它回答的是：这个物品在语义和属性上是否符合用户被推断出的目标域兴趣。

**重叠用户证据 $c^{\text{ov}}$**

先在源域寻找与用户 $u$ 相似的重叠用户，再查看这些重叠用户在目标域真实交互过的物品。候选物品越接近这些真实物品，$c^{\text{ov}}$ 越高。

冷用户的目标域交互不会参与这个过程，只使用重叠用户提供的监督。

**模型证据 $c^{\text{model}}$**

使用当前 EMA 教师对候选物品的预测分数。为了让不同用户的分数可比较，会根据该用户对整个目标域目录的分数分布进行标准化，再通过 sigmoid 映射到 $0 \sim 1$。

**5. 学习可信校准函数**

V3 不直接平均三个证据，而是利用重叠用户训练一个低容量校准器。

对重叠用户生成语义候选和 EMA 候选，然后根据其真实目标域交互标注：

$$y_{ui} = \begin{cases} 1, & i \in \mathcal{I}_u^t, \\ 0, & i \notin \mathcal{I}_u^t. \end{cases}$$

校准器为：

$$\rho_{ui} = \sigma\left(w_{\text{sem}}\tilde{c}_{ui}^{\text{sem}} + w_{\text{ov}}\tilde{c}_{ui}^{\text{ov}} + w_{\text{model}}\tilde{c}_{ui}^{\text{model}} + b\right),$$

其中三个权重通过 `softplus` 保证非负，避免某项证据被错误地反向使用。由于正样本很稀疏，训练采用带正类权重的 BCE。

重叠用户按照 60%/20%/20% 划分为训练、验证和测试用户。训练集学习校准器，验证集确定接纳阈值，测试集只用于诊断校准质量。

**6. 接纳新伪交互**

EMA 提出的候选不能直接加入伪交互集合，需要同时满足：

1. 校准置信度 $\rho_{ui}$ 高于验证集确定的阈值。
2. 置信度不能明显低于该用户原始 Top-5 锚点。
3. 用户可信门控 $g_u$ 高于最低要求。
4. 候选不在当前伪交互集合中。
5. 候选不属于该用户已知目标域正样本，避免重复。
6. 通过本轮全局接纳数量限制。

接纳后：

$$\widetilde{\mathcal{I}}_u^{(r+1)} = \widetilde{\mathcal{I}}_u^{(r)} \cup \mathcal{A}_u^{(r)}.$$

**7. 扩展后的同步更新**

新候选加入后，V3 会同步更新三个部分：

- 重新构造直接伪交互 BPR 样本。
- 使用新置信度更新每个伪交互的损失权重：

$$\omega_{ui} = \max(\rho_{ui}, \epsilon)^p.$$

- 更新残差 Adapter 的训练候选和冷用户门控 $g_u$。

因此 V3 不是简单地向数据中追加几个物品，而是让伪交互集合、训练权重、残差候选和用户可信度一起演化。

**8. Strict、Balanced 和 Broad**

三个设置控制候选扩展的保守程度：

| 设置 | 最低用户门控 | 每轮全局新增上限 | 候选保留范围 | 锚点要求 |
|---|---|---|---|---|
| Strict | 0.75 | 冷用户数的 0.25% | 置信度最高 25% | 不低于锚点 |
| Balanced | 0.50 | 0.50% | 最高 50% | 不低于锚点的 75 |
| Broad | 0.25 | 1.00% | 全部合格候选 | 不低于锚点的 50 |

Strict 更强调可靠性，Broad 更强调覆盖率，Balanced 位于两者之间。

**一句话概括**

V3 使用初始 Top-5 作为固定可信锚点，让 EMA 教师从全物品空间提出新候选，再由重叠用户监督下学习到的三证据校准函数判断候选是否可信，最终把通过筛选的候选同步用于 backbone 伪监督和残差 Adapter 训练。

主要实现位于 grounded_expandable_pseudo.py (line 32)，v2.1 的损失和推理逻辑位于 grounded_adaptive_pseudo.py (line 238)。

9:18 AM

## 三种伪交互构造的重叠用户命中率

Hit@K 表示至少有一个 Top-K 伪物品命中该重叠用户真实目标域交互的用户比例。插件实际使用官方 Top-5，因此 **Hit@5** 是主指标；其余截止位置用于诊断 Top-100 排序质量。

| 任务 | 伪交互构造 | Hit@1 | Hit@5 | Hit@10 | Hit@20 | Hit@50 | Hit@100 |
|---|---|---|---|---|---|---|---|
| Cloth→Sport | 原始物品级 G | 0.7673% | **1.8223%** | 3.2289% | 5.7225% | 10.9655% | 17.6471% |
| Cloth→Sport | **用户级 G** | 0.7033% | **2.1739%** | 3.1650% | 4.9552% | 10.0703% | 16.2084% |
| Cloth→Sport | Direct Semantic | 2.0780% | **7.2890%** | 11.4770% | 17.7749% | 27.9092% | 38.1074% |
| Cloth→Sport | Popularity | 1.8862% | **7.3529%** | 9.4949% | 12.7877% | 25.0000% | 37.4041% |
| Phone→Elec | 原始物品级 G | 0.0274% | **0.0822%** | 0.1827% | 0.4202% | 1.3338% | 2.6768% |
| Phone→Elec | **用户级 G** | 2.5854% | **13.0093%** | 19.5871% | 27.7270% | 42.6000% | 56.0022 |
| Phone→Elec | Direct Semantic | 1.9094% | **4.6958%** | 6.9614% | 10.3965% | 16.3804% | 22.6110% |
| Phone→Elec | Popularity | 7.3451% | **18.0066%** | 26.7038% | 35.2914% | 51.4160% | 63.5940 |
| Book→Music | **用户级 G** | 0.7663% | **3.3525%** | 5.4598% | 9.1954% | 18.1034% | 25.5747% |
| Book→Music | Direct Semantic | 0.3831% | **2.0115%** | 5.4598% | 10.7280% | 19.4444% | 30.6513% |
| Book→Music | Popularity | 10.1533% | **30.1724%** | 39.8467% | 52.0115% | 64.7510% | 75.0958% |

### 评估口径与来源

- Cloth→Sport 使用 3,128 个重叠用户，Phone→Elec 使用 10,946 个重叠用户，Book→Music 使用 1,044 个重叠用户。
- 生成兴趣和伪交互时只使用重叠用户的源域交互，未把目标域交互输入 LLM 或召回模块。
- 由于该数据划分的 warm validation/test 为空，目标域训练交互仅在生成完成后作为诊断标签。因此这些命中率用于比较伪交互质量，不是独立测试集推荐指标。
- 原始物品级 G 来自各任务 target_pattern_pseudo/item_bridge_v1_archive/overlap_pseudo_quality.json；用户级 G 来自 target_pattern_pseudo/overlap_pseudo_quality.json。
- Direct Semantic 原目录没有保存重叠用户质量文件。Cloth→Sport 与 Phone→Elec 数值于 2026-09-01、Book→Music 数值于 2026-09-08，均使用现有 overlap_user_interests.jsonl、兴趣语义向量和目标物品语义向量，严格复用 `direct_semantic_pseudo.py` 的“兴趣权重均值 + 余弦 Top-100”逻辑重新计算。
- Popularity 直接按目标域训练交互频次对物品做全局排序，所有重叠用户共享同一推荐列表；数值读取自相同 `overlap_pseudo_quality.json` 中的 `metrics.popularity`，仅作为诊断参照，不属于只依赖源域信息的伪交互构造方法。
- 用户级 G

Worked for 2m 9s

**什么是用户级 $G$**

用户级 $G$ 是一个"语义兴趣空间到目标域协同空间"的映射网络：

$$G : \mathbb{R}^{d_{\text{sem}}} \to \mathbb{R}^{d_{\text{collab}}}.$$

它把一个用户的目标域兴趣语义向量 $q_u$ 映射成目标域协同用户表示：

$$\hat{\mathbf{e}}^t_u = G(\mathbf{q}_u).$$

然后用 $\hat{\mathbf{e}}^t_u$ 与目标域物品协同嵌入计算相似度，召回伪交互物品。

这里的 $G$ 是伪交互构造模块中的语义桥接器，不是 EMCDR 自己用于跨域迁移的映射网络。

---

**1. 先训练目标域 LightGCN**

使用目标域训练交互训练一个独立的 LightGCN，得到：

$$\mathbf{e}^t_u$$

目标域训练用户 $u$ 的协同嵌入，以及：

$$\mathbf{e}^t_i$$

目标域物品 $i$ 的协同嵌入。

当前设置中，LightGCN 的用户和物品嵌入均为 64 维。它提供了用户级 $G$ 要学习进入的目标协同空间。

---

**2. 构造用户级训练样本**

对于每个至少有两个目标域训练交互的用户 $u$，假设其目标域交互集合为：

$$\mathcal{I}^t_u = \{i_1, i_2, \ldots, i_n\}.$$

随机留出一个真实交互物品 $i^+_u$，其余物品作为兴趣上下文：

$$\mathcal{C}_u = \mathcal{I}^t_u \setminus \{i^+_u\}.$$

每个目标物品都有对应的语义嵌入 $\mathbf{a}_i$。将上下文物品的语义嵌入求平均并归一化：

$$\mathbf{q}_u = \text{Norm}\left(\frac{1}{|\mathcal{C}_u|}\sum_{i \in \mathcal{C}_u} \mathbf{a}_i\right).$$

如果交互太多，最多采样 32 个上下文物品。

因此，一条 $G$ 的训练样本是：

$$(\mathbf{q}_u, \mathbf{e}^t_{i^+_u}).$$

输入是用户级的兴趣语义聚合，而不是单个物品语义向量。

---

**3. $G$ 的网络结构**

当前实现为一个两层 MLP：

$$\mathbf{q}_u \xrightarrow{\text{Linear}} 512 \xrightarrow{\text{GELU}} \xrightarrow{\text{LayerNorm}} \xrightarrow{\text{Dropout}} \xrightarrow{\text{Linear}} 64 \xrightarrow{\ell_2\ \text{Norm}} \hat{\mathbf{e}}^t_u.$$

即：

```
Plain text
3072-dimensional semantic query
        ↓
Linear(3072, 512)
        ↓
GELU + LayerNorm + Dropout
        ↓
Linear(512, 64)
        ↓
L2 normalization
        ↓
64-dimensional collaborative query
```

具体实现在 target_pattern_pseudo.py (line 107)。

---

**4. $G$ 如何训练**

训练目标不只是让输出接近目标域用户嵌入，还要求它能够召回该用户留出的真实物品。

**排序损失**

对真实物品 $i^+_u$ 和从用户历史外采样的负物品 $i^-_u$：

$$\mathcal{L}_{\text{rank}} = -\log \sigma\left(\frac{G(\mathbf{q}_u)^\top \mathbf{e}^t_{i^+_u} - G(\mathbf{q}_u)^\top \mathbf{e}^t_{i^-_u}}{\tau}\right).$$

它要求映射后的用户向量更接近真实正物品，而不是负物品。

**用户对齐损失**

$$\mathcal{L}_{\text{align}} = 1 - \cos\left(G(\mathbf{q}_u), \mathbf{z}^t_u\right).$$

它让映射结果接近 LightGCN 学到的目标域用户协同表示。

**对比学习损失**

同一批次中，$G(\mathbf{q}_u)$ 应当匹配用户 $u$ 的协同向量，而不是其他用户的协同向量。

**防坍缩约束**

如果所有用户都被 $G$ 映射到相似位置，输出会塌的方差就会过小。方差约束用于避免这种映射坍缩。

最终为：

$$\mathcal{L}_G = \mathcal{L}_{\text{rank}} + \lambda_{\text{align}}\mathcal{L}_{\text{align}} + \lambda_{\text{con}}\mathcal{L}_{\text{con}} + \lambda_{\text{var}}\mathcal{L}_{\text{var}}.$$

当前对应权重为 1、0.2、0.02、0.1，训练实现位于 target_pattern_pseudo.py (line 2342)。

---

**5. 如何选择最好的 $G$**

在验证用户上同样留出一个真实物品，并执行全目标域物品召回。

验证时会：

1. 计算 $G(q_u)$；
2. 与所有目标域物品协同嵌入计算内积；
3. 排除用于构造 $q_u$ 的上下文物品；
4. 检查留出的真实物品是否进入 Top-20；
5. 根据 Recall@20、NDCG@20 和用户表示对齐程度选择 checkpoint。

因此，$G$ 的选择标准与最终"召回目标域物品"的任务直接一致。

---

**6. 冷启动用户如何使用 $G$**

对于没有目标域交互的冷用户 $u$，只读取其源域交互。LLM 在一次调用中：

1. 将源域物品划分为若干兴趣组；
2. 描述每组源域兴趣；
3. 将同一兴趣迁移成目标域物品属性模式。

例如得到：

```
Plain text
兴趣1：轻量、透气、适合跑步的运动服饰，权重 0.6
兴趣2：适合户外骑行的防风装备，权重 0.4
```

对每个目标域兴趣模式编码，并按源域物品支持比例加权：

$$\mathbf{q}_u = \text{Norm}\left(\sum_{g=1}^{M} \alpha_{ug}\mathbf{s}^t_{ug}\right), \qquad \sum_g \alpha_{ug} = 1.$$

然后执行：

$$\hat{\mathbf{e}}^t_u = G(\mathbf{q}_u),$$

并计算所有目标物品的分数：

$$s(u, i) = \hat{\mathbf{e}}^t_u \cdot \mathbf{e}^t_i.$$

分数最高的物品构成用户的伪交互集合。当前缓存 Top-100 排名，假插件默认使用前 5 个。

召回逻辑位于 target_pattern_pseudo.py (line 2712)。

---

**7. 为什么叫"用户级"，而不是物品级**

原始物品级 $G$ 学的是：

$$G_{\text{item}}(\mathbf{a}_i) \approx \mathbf{e}^t_i.$$

也就是"单个物品语义表示 → 单个物品协同表示"。

但冷用户真正输入的是多个兴趣模式的加权聚合：

$$\mathbf{q}_u = \sum_g \alpha_{ug}\mathbf{s}^t_{ug}.$$

直接把这种用户级聚合向量输入物品级映射，会出现训练和推理输入不一致。

用户级 $G$ 学的是：

$$G_{\text{user}}\left(\text{Aggregate}\{\mathbf{a}_i : i \in \mathcal{I}^t_u\}\right) \approx \mathbf{z}^t_u.$$

训练和推理面对的都是"由多个兴趣或多个物品组成的用户语义表示"，所以更符合实际召回过程。

---

**8. 是否使用目标域交互**

需要区分两个阶段：

- **训练 $G$ 时使用目标域训练交互。** LightGCN、用户语义上下文、正负物品和留出验证物品都来自目标域训练用户。
- **给冷启动用户生成伪交互时不使用该冷用户的目标域交互。** 冷用户只提供源域历史，由 LLM 推断目标域兴趣，再经过已经训练并冻结的 $G$ 完成召回。

因此，用户级 $G$ 利用目标域中的其他训练用户学习普遍的"语义兴趣到协同偏好"规律，但不会读取待推荐冷用户的目标域真实答案。

9:59 AM

## 结果总表

阶段 2 v2.1、Popularity 与新版 v3 在原四个 Backbone 上均已完成 8/8。CD-CDR Normal（修正版）作为独立对照行且不覆盖旧版结果。旧阶段 3 结果已撤下；表中阶段 3 数值全部来自以各行阶段 2 v2.1 最优配置为底座重新运行的新版 v3。三分类可信伪监督（TriClass）也已完成 8/8。

| 任务 | Backbone | Pure Backbone | 原始物品级 G | 用户级 G | Direct Semantic | Popularity | 阶段 2 v1 |
|---|---|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | 0.0177 / 0.0182 | 0.0170 / 0.0169 (-0.0007 / -0.0013) | 0.0190 / 0.0181 (+0.0013 / -0.0001) | 0.0179 / 0.0176 (+0.0002 / -0.0006) | 0.0195 / 0.0177 (+0.0018 / -0.0005) | 0.0174 / (-0.0003 -0.0005) |
| Cloth→Sport | UniCDR | 0.0425 / 0.0352 | 0.0425 / 0.0352 (+0.0000 / +0.0000) | 0.0425 / 0.0352 (+0.0000 / +0.0000) | 0.0425 / 0.0352 (+0.0000 / +0.0000) | 0.0409 / 0.0297 (-0.0016 / -0.0055) | 0.0288 / 0.0234 (-0.0137 -0.0118) |
| ~~Cloth→Sport~~ | ~~CD-CDR~~ | ~~0.0514 / 0.0479~~ | ~~0.0533 / 0.0498 (+0.0019 / +0.0019)~~ | ~~0.0549 / 0.0527 (+0.0035 / +0.0048)~~ | **~~0.0570 / 0.0527~~** (+0.0056 / +0.0048)~~ | ~~0.0531 / 0.0488 (+0.0017 / +0.0009)~~ | ~~0.0549 / 0.0527 (+0.003 +0.0048~~ |
| Cloth→Sport | CD-CDR Normal（修正版） | 0.0152 / 0.0178 | 0.0178 / 0.0181 (+0.0026 / +0.0003) | 0.0182 / 0.0186 (+0.0030 / +0.0008) | 0.0178 / 0.0188 (+0.0026 / +0.0010) | 0.0185 / 0.0168 (+0.0033 / -0.0010) | 0.0189 / (+0.003 +0.0019) |
| Cloth→Sport | CDRIB | 0.0198 / 0.0167 | 0.0239 / 0.0185 (+0.0041 / +0.0018) | 0.0239 / 0.0203 (+0.0041 / +0.0036) | 0.0248 / 0.0204 (+0.0050 / +0.0037) | 0.0240 / 0.0205 (+0.0042 / +0.0038) | 0.0277 / 0.0244 (+0.007 +0.0077 |
| Phone→Elec | EMCDR | 0.0405 / 0.0471 | 0.0398 / 0.0470 (-0.0007 / -0.0001) | 0.0406 / 0.0469 (+0.0001 / -0.0002) | 0.0399 / 0.0466 (-0.0006 / -0.0005) | 0.0403 / 0.0469 (-0.0002 / -0.0002) | 0.0401 / (-0.0004 -0.0004) |
| Phone→Elec | UniCDR | 0.0537 / 0.0619 | 0.0537 / 0.0606 (+0.0000 / -0.0013) | 0.0541 / 0.0589 (+0.0004 / -0.0030) | 0.0511 / 0.0599 (-0.0026 / -0.0020) | 0.0563 / 0.0576 (+0.0026 / -0.0043) | 0.0535 / (-0.0002 +0.0000 |
| ~~Phone→Elec~~ | ~~CD-CDR~~ | ~~0.0432 / 0.0459~~ | ~~0.0432 / 0.0459 (+0.0000 / +0.0000)~~ | ~~0.0431 / 0.0457 (-0.0001 / -0.0002)~~ | ~~0.0427 / 0.0474 (-0.0005 / +0.0015)~~ | ~~0.0436 / 0.0411 (+0.0004 / -0.0048)~~ | ~~0.0430 / 0.0456 (-0.0002 -0.0003)~~ |
| Phone→Elec | CD-CDR Normal（修正版） | 0.0316 / 0.0355 | 0.0324 / 0.0388 (+0.0008 / +0.0033) | 0.0408 / 0.0417 (+0.0092 / +0.0062) | 0.0316 / 0.0355 (+0.0000 / +0.0000) | 0.0411 / 0.0437 (+0.0095 / +0.0082) | 0.0338 / (+0.002 +0.0036 |
| Phone→Elec | CDRIB | 0.0384 / 0.0477 | 0.0410 / 0.0492 (+0.0026 / +0.0015) | 0.0416 / 0.0443 (+0.0032 / -0.0034) | 0.0451 / 0.0509 (+0.0067 / +0.0032) | 0.0437 / 0.0487 (+0.0053 / +0.0010) | 0.0512 / (+0.0128 +0.0073 |

## 三分类可信伪监督（TriClass，2026-09-08 启动）

这是独立新增版本，不覆盖已有 v1、v2、v2.1 或 v3。范围为 Cloth→Sport、Phone→Elec，各验证 EMCDR、UniCDR、CD-CDR Normal、CDRIB。

### 离线构建与训练方式

1. 复用现有用户兴趣和物品语义向量，不重新调用 LLM 或 embedding API。目标 LightGCN 与用户级 G 重新训练，排除全部重叠用户的目标域边，避免评估查询用户时泄漏其目标监督；源域 LightGCN 复用通过指纹检查的缓存。
2. 合并语义、G、Popularity 各 Top-50 候选，去重后最多 150 个。四项证据为语义余弦、G 匹配余弦、源域相似重叠训练用户的真实物品交互投票（排除自己）、log(1+物品热度)。
3. 可信分类器仍由重叠用户训练：固定按用户划分 60%/20%/20% 训练、验证和测试。标签为精确命中 Hit、偏好邻近 Near、其余 Unsupported；Unsupported 不等于明确不喜欢。Near 根据目标协同空间的物品 Top-20 邻居定义。
4. 使用 4→3 线性 softmax，以验证集交叉熵早停，并仅在验证集选择筛选阈值；测试重叠用户仅用于质量审计。冷用户权重为 `p_hit + eta * p_near`，最多保留 5 个过阈值候选，缺少可靠候选时不补齐。
5. Backbone 只增加加权 pseudo BPR，不更改推理打分。每批均匀抽样 16 个冷用户，按固定 16×5 槽位归一化，保留绝对置信度强弱；负例排除完整候选池和已知训练正样本。

### 搜索登记与状态

- 固定 `seed=999`；Backbone 使用当前 Pure Backbone 配置，CD-CDR 使用 Normal 版本。
- `pseudo_loss_weight=[0.01, 0.1, 1.0]`，`near_support_weight=[0.0, 0.25, 0.5]`，每个任务 9 组，共 8 个搜索任务、72 组，全部为非零伪监督权重。
- 状态快照：2026-09-11 03:42:36+0800。两项离线构建和 8 个 Backbone 搜索均已完成，8/8 成功、0 失败；后台队列已正常结束。
- 已完成最佳配置（字段顺序为 `pseudo_loss_weight, near_support_weight`）：Cloth→Sport 的 EMCDR `(0.1, 0.25)`、UniCDR `(0.1, 0.0)`、CD-CDR Normal `(1.0, 0.0)`、CDRIB `(0.1, 0.25)`；Phone→Elec 的 EMCDR `(0.1, 0.0)`、UniCDR `(1.0, 0.5)`、CD-CDR Normal `(1.0, 0.25)`、CDRIB `(1.0, 0.5)`。
- 后台队列 PID `567906`；状态文件 `/data/guqiwen/CDRec/src/triclass_runs/20260908/status.json`。
- 离线日志和各搜索标准输出位于 `/data/guqiwen/CDRec/src/triclass_runs/20260908/`；两个数据方向各自 split 目录下的 `grounded_triclass/` 保存共享缓存、`diagnostics.json` 和 `manifest.json`。
- 原 benchmark 评测逻辑保持不变；最终推荐性能的展示沿用本页统计口径。离线校准的验证集选择与原 benchmark 的测试集 Best Parameters 汇总是不同环节。

## 二分类与三分类对比：Near 类作用（已完成，2026-09-18 复核）

**4/4 次离线二分类构建与 16/16 次模型训练全部完成**，无运行或等待任务。2026-09-18 复核：下表 16 个二分类结果、8 个 TriClass 所选结果和 8 个匹配 λ 的 η=0 参考结果，共 **32 个数值单元格已全部填齐并与最终日志一致**；本表原先已无空缺，本次保留其正确数值。复用原 TriClass 候选、四项证据和重叠用户划分，不重复调用 LLM。每格为 **R@20 / N@20**。

### 实验设置

- Hit-only：Hit 为正类，Near 与 Unsupported 合并为负类，重新训练 4→2 线性分类器。
- Hit+Near：Hit 与 Near 合并为正类，Unsupported 为负类，重新训练 4→2 线性分类器。
- TriClass：保持 Hit、Near、Unsupported 三类。最后一列是在同一三分类模型下只使用 p_Hit 的匹配 λ 参考，不是二分类器。
- 版本说明：本轮 CDRIB 二分类及三分类参考均为原非确定性图传播版本，不替换成确定性预算实验的结果；未做独立整轮确定性复现，相关小幅差异需谨慎解读。
- 每组固定 seed=999，沿用对应 TriClass 的 backbone 参数与 pseudo_loss_weight；二分类使用自身正类概率和验证阈值，不额外搜索 λ。原版 η=0/0.25/0.5 的所选配置保持不变。

| 数据集 | Backbone | Hit-only 二分类 | Hit+Near 二分类 | TriClass 所选配置 | TriClass η=0，匹配 λ |
|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | 0.0181 / 0.0188 | 0.0180 / 0.0186 | 0.0192 / 0.0181 | 0.0173 / 0.0178 |
| Cloth→Sport | UniCDR | 0.0317 / 0.0266 | 0.0494 / 0.0402 | 0.0561 / 0.0493 | 0.0561 / 0.0493 |
| Cloth→Sport | CD-CDR Normal | 0.0206 / 0.0219 | 0.0168 / 0.0177 | 0.0256 / 0.0250 | 0.0256 / 0.0250 |
| Cloth→Sport | CDRIB | 0.0250 / 0.0234 | 0.0290 / 0.0242 | 0.0256 / 0.0223 | 0.0225 / 0.0207 |
| Phone→Elec | EMCDR | 0.0399 / 0.0467 | 0.0401 / 0.0469 | 0.0406 / 0.0472 | 0.0406 / 0.0472 |
| Phone→Elec | UniCDR | 0.0599 / 0.0727 | 0.0531 / 0.0497 | 0.0619 / 0.0689 | 0.0603 / 0.0729 |
| Phone→Elec | CD-CDR Normal | 0.0428 / 0.0484 | 0.0423 / 0.0462 | 0.0479 / 0.0539 | 0.0405 / 0.0468 |
| Phone→Elec | CDRIB | 0.0452 / 0.0517 | 0.0480 / 0.0541 | 0.0520 / 0.0556 | 0.0481 / 0.0491 |

### 结果解读

- TriClass 对 Hit-only：Recall 8/8 更高，NDCG 5/8 更高。
- TriClass 对 Hit+Near：Recall 7/8 更高，NDCG 6/8 更高。
- Cloth→Sport UniCDR 的 TriClass η=0 仍优于 Hit-only，说明训练时单独区分 Near 与使用时给 Near 加权是两个不同作用。
- 不支持"三分类在每个指标上都更优"：Cloth→Sport CDRIB 的 Hit+Near 二分类双指标更高；Cloth→Sport EMCDR 和 Phone→Elec UniCDR 也有二分类 NDCG 更高的情况。
- 这些结果支持 Near 独立建模通常有价值，但仍是固定配置的替换实验。分类目标变化也改变分数尺度、阈值、覆盖率和伪监督数量，严格机制归因还需要匹配预算对照。

### 文件与方案

- 结果：`src/binary_triclass_runs/20260913/performance.csv`、`confidence.csv`、`status.json`。
- 训练日志：同目录的 `train_<模型>_<ClothSport或PhoneElec>_<hit_only或hit_near>.log`。
- 主 TriClass 参考：`src/triclass_runs/20260908/<模型>_<任务>.log`。
- 完整方案：三分类可信伪监督（TriClass）：完整研究方案与实验依据（2026-09-14）

## TriClass 四项证据逐项移除（已完成，2026-09-18 核验）

### 实验口径

以完整三分类可信伪监督 TriClass 为基准，Cloth→Sport、Phone→Elec 两个方向，各用 EMCDR、UniCDR、CD-CDR Normal、CDRIB 四个 backbone；四种变体共 **32 次单配置训练**，运行于 **10.32.80.5**。每个方向每种消融先生成一次共享缓存，共 8 次分类器重训，供四个 backbone 复用。

- **w/o Semantic**：可信分类器不再接收语义余弦相似度。
- **w/o G**：可信分类器不再接收用户级 G 的匹配分数（bridge cosine）。
- **w/o Overlap Vote**：可信分类器不再接收源域相似重叠用户的真实交互投票。
- **w/o Popularity**：可信分类器不再接收物品对数热度。

**本轮消融的是可信分类器的输入证据，不是召回路由。** 三路召回候选、原始 Hit/Near/Unsupported 标签、重叠用户 Train/Validation/Test 划分均复用原缓存；不重新调用 LLM/embedding API，不重训 G 或 LightGCN。移除输入在训练和推理前恒置零，标准化后仍为零、对应线性权重始终为零，等价于仅使用另外三项证据。

分类器按原设置重新拟合；阈值仍按原规则在原重叠验证用户上选择。Top-K、seed=999、backbone 超参数、伪监督 λ 与 Near 权重 η 全部固定为对应完整 TriClass 配置，不搜索消融参数。这里采用原始完整重叠监督预算，与上一个降低重叠比例的实验不同。

### 完成状态

.5 的 **8/8 个共享消融缓存、32/32 次单配置训练全部完成，0 运行、0 等待、0 失败**，队列于 **2026-09-16 13:51:51（UTC+8）** 结束。全部最终训练日志已与汇总 CSV 逐项核对一致。

整轮日志和汇总于 **2026-09-16 13:52:06（UTC+8）** 回传本机 `src/triclass_evidence_runs/20260915/`。2026-09-18 重新核对两端 44 个顶层日志及汇总文件，SHA-256 全部一致；远端原件保留。原部署的代码/输入文件及缓存校验、两端测试记录仍保留。

新增登记的 Phone→Elec / CDRIB 四项最终结果均已填入下表，不再保留旧 PID、旧 epoch 或运行中状态。

### 推荐性能：R@20 / N@20

每格第一行为 **R@20 / N@20**，第二行为 **ΔR / ΔN**。Δ 为 **移除证据后的变体 − 完整 TriClass**，不是相对 Pure。完整 TriClass 来自 `src/triclass_runs/20260908/` 匹配固定 λ、η、seed 的最终结果，32 格消融结果已全部补齐。

**版本说明：本轮证据消融的 CDRIB 为原非确定性图传播实现，完整参考也来自该版本；不替换成预算表或召回对比表中的确定性 CDRIB。** 其差值保留作本轮记录，但没有整轮确定性重复保证。

| 任务 | Backbone | 完整 TriClass | w/o Semantic | w/o G | w/o Overlap Vote | w/o Popularity | 状态 |
|---|---|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | 0.0192 / 0.0181 | 0.0193 / 0.0184<br>Δ +0.0001 / | 0.0185 / 0.0186<br>Δ -0.0007 / | 0.0168 / 0.0178<br>Δ -0.0024 / | 0.0179 / 0.0184<br>Δ -0.0013 / | Semantic<br>G：Reca |

| 任务 | Backbone | 完整 TriClass | w/o Semantic | w/o G | w/o Overlap Vote | w/o Popularity | 状态 |
|---|---|---|---|---|---|---|---|
| | | | +0.0003 | +0.0005 | -0.0003 | +0.0003 | NDCG 升<br>Overlap<br>双降<br>Popularit<br>Recall 降<br>NDCG 升 |
| Cloth→Sport | UniCDR | 0.0561 / 0.0493 | 0.0433 / 0.0398<br>Δ -0.0128 / -0.0095 | 0.0520 / 0.0465<br>Δ -0.0041 / -0.0028 | 0.0521 / 0.0476<br>Δ -0.0040 / -0.0017 | 0.0422 / 0.0362<br>Δ -0.0139 / -0.0131 | Semantic<br>G：双降<br>Overlap<br>双降<br>Popularit<br>降 |
| Cloth→Sport | CD-CDR Normal | 0.0256 / 0.0250 | 0.0169 / 0.0197<br>Δ -0.0087 / -0.0053 | 0.0177 / 0.0206<br>Δ -0.0079 / -0.0044 | 0.0188 / 0.0210<br>Δ -0.0068 / -0.0040 | 0.0251 / 0.0260<br>Δ -0.0005 / +0.0010 | Semantic<br>G：双降<br>Overlap<br>双降<br>Popularit<br>Recall 降<br>NDCG 升 |
| Cloth→Sport | CDRIB | 0.0256 / 0.0223 | 0.0225 / 0.0216<br>Δ -0.0031 / -0.0007 | 0.0245 / 0.0252<br>Δ -0.0011 / +0.0029 | 0.0258 / 0.0238<br>Δ +0.0002 / +0.0015 | 0.0225 / 0.0223<br>Δ -0.0031 / 0.0000 | Semantic<br>G：Reca<br>NDCG 升<br>Overlap<br>双升<br>Popularit<br>Recall 降<br>NDCG 持 |
| Phone→Elec | EMCDR | 0.0406 / 0.0472 | 0.0404 / 0.0470<br>Δ -0.0002 / -0.0002 | 0.0404 / 0.0471<br>Δ -0.0002 / -0.0001 | 0.0403 / 0.0467<br>Δ -0.0003 / -0.0005 | 0.0403 / 0.0471<br>Δ -0.0003 / -0.0001 | Semantic<br>G：双降<br>Overlap<br>双降<br>Popularit<br>降 |
| Phone→Elec | UniCDR | 0.0619 / 0.0689 | 0.0599 / 0.0671<br>Δ -0.0020 / -0.0018 | 0.0591 / 0.0668<br>Δ -0.0028 / -0.0021 | 0.0539 / 0.0501<br>Δ -0.0080 / -0.0188 | 0.0604 / 0.0702<br>Δ -0.0015 / +0.0013 | Semantic<br>G：双降<br>Overlap<br>双降<br>Popularit<br>Recall 降<br>NDCG 升 |
| Phone→Elec | CD-CDR Normal | 0.0479 / 0.0539 | 0.0433 / 0.0498<br>Δ -0.0046 / -0.0041 | 0.0470 / 0.0522<br>Δ -0.0009 / -0.0017 | 0.0373 / 0.0455<br>Δ -0.0106 / -0.0084 | 0.0446 / 0.0508<br>Δ -0.0033 / -0.0031 | Semantic<br>G：双降<br>Overlap<br>双降<br>Popularit<br>降 |
| Phone→Elec | CDRIB | 0.0520 / 0.0556 | 0.0477 / 0.0538<br>Δ -0.0043 / -0.0018 | 0.0457 / 0.0519<br>Δ -0.0063 / -0.0037 | 0.0428 / 0.0514<br>Δ -0.0092 / -0.0042 | 0.0481 / 0.0532<br>Δ -0.0039 / -0.0024 | Semantic<br>G：双降<br>Overlap<br>双降<br>Popularit<br>降 |

## 固定训练参数

| 任务 | Backbone | 伪监督 λ | Near 权重 η | seed |
|---|---|---|---|---|
| Cloth→Sport | EMCDR | 0.1 | 0.25 | 999 |
| Cloth→Sport | UniCDR | 0.1 | 0 | 999 |
| Cloth→Sport | CD-CDR Normal | 1 | 0 | 999 |

| 任务 | Backbone | 伪监督 λ | Near 权重 η | seed |
|---|---|---|---|---|
| Cloth→Sport | CDRIB | 0.1 | 0.25 | 999 |
| Phone→Elec | EMCDR | 0.1 | 0 | 999 |
| Phone→Elec | UniCDR | 1 | 0.5 | 999 |
| Phone→Elec | CD-CDR Normal | 1 | 0.25 | 999 |
| Phone→Elec | CDRIB | 1 | 0.5 | 999 |

### 可信质量登记（8/8 已完成）

在相同的原重叠测试用户、相同候选物品上评估。Hit AUPRC、Hit+Near AUPRC 越高越好，三类 Brier 与 ECE-15 越低越好；另在输出文件中保留各 η 下的筛选后 Hit Precision、Near 占比、用户覆盖率及伪交互数量。

| 任务 | 变体 | Hit AUPRC | Hit+Near AUPRC | Brier | ECE-15 | 状态 |
|---|---|---|---|---|---|---|
| Cloth→Sport | w/o Semantic | 0.031717 | 0.242629 | 0.116214 | 0.006067 | 已完成 |
| Cloth→Sport | w/o G | 0.045655 | 0.209764 | 0.118236 | 0.006851 | 已完成 |
| Cloth→Sport | w/o Overlap Vote | 0.022462 | 0.249752 | 0.115946 | 0.006279 | 已完成 |
| Cloth→Sport | w/o Popularity | 0.046141 | 0.125904 | 0.126648 | 0.012802 | 已完成 |
| Phone→Elec | w/o Semantic | 0.054286 | 0.539696 | 0.278107 | 0.009083 | 已完成 |
| Phone→Elec | w/o G | 0.068168 | 0.492053 | 0.289573 | 0.030158 | 已完成 |
| Phone→Elec | w/o Overlap Vote | 0.028020 | 0.540036 | 0.278310 | 0.008282 | 已完成 |
| Phone→Elec | w/o Popularity | 0.065134 | 0.463092 | 0.298565 | 0.018067 | 已完成 |

### 完整结果汇总

| 变体 | 已完成 | 双降 | 双升 | 其他变化（相对完整 TriClass） |
|---|---|---|---|---|
| w/o Semantic | 8 | 7 | 1 | 无 |
| w/o G | 8 | 6 | 0 | 2 组 Recall 降、NDCG 升 |
| w/o Overlap Vote | 8 | 7 | 1 | 无 |
| w/o Popularity | 8 | 4 | 0 | 3 组 Recall 降、NDCG 升；1 组 Recall 降、NDCG 持平 |

32 个消融结果中，**24 个双降、2 个双升、5 个 Recall 降/NDCG 升、1 个 Recall 降/NDCG 持平**。这里的“双降”表示完整证据版本更好，与预算表中 TriClass 相对 Pure 的“双升”含义不同。

- 移除 Semantic 与 Overlap Vote 各有 7/8 组双降，移除 G 有 6/8 组双降；不能称为所有组合均不可缺少。
- Cloth→Sport / UniCDR 移除 Semantic：0.0561 / 0.0493 → 0.0433 / 0.0398；Phone→Elec / UniCDR 移除 Overlap Vote：0.0619 / 0.0689 → 0.0539 / 0.0501。
- 移除 Popularity 的变化仍较混合：4 组双降、3 组 Recall 降/NDCG 升、1 组 Recall 降/NDCG 持平。
- 两个双升反例保留：Cloth→Sport / EMCDR 移除 Semantic，以及 Cloth→Sport / CDRIB 移除 Overlap Vote。
- 排除尚无确定性重复保证的 CDRIB 后，其余 6 组中，移除 Semantic/G/Overlap Vote/Popularity 的双降数量分别为 5/6、5/6、6/6、3/6。以上均为固定种子、固定配置结果，不作显著性结论。

### 文件与回传

- 新增构建器：`src/models/grounded_triclass_evidence_ablation.py`；配置：`src/configs/model/GroundedTriClassEvidence.yaml`。
- 调度与回传：`src/tools/run_triclass_evidence_study.py`；测试：`src/tools/test_triclass_evidence_study.py`。不修改已有模型或 benchmark。
- .5 独立目录：`/home/guqiwen/CDRec/src/triclass_evidence_runs/20260915/`，包含代码快照、输入快照、消融缓存、逐实验日志及 `status.json`、`performance.csv`、`confidence.csv`。
- 本机接收目录：`/data/guqiwen/CDRec/src/triclass_evidence_runs/20260915/`。32 份训练日志、8 份构建日志和汇总文件已完整回传，并逐文件核对 SHA-256；远端原件保留。

## 单路召回、三路简单合并和三路可信筛选对比（数量对齐，已完成，2026-09-18 核验）

**前五列是召回与排序的数量控制实验，新增第六个方法列为完整 TriClass 的已有结果。** 第五种方式“三路可信排序（等权 Top-5）”只沿用三分类可信分数排序，取消阈值过滤和逐样本置信度加权；完整 TriClass 保留这两项，不能与第五列混称。三种单路方式均不使用可信函数做重排、过滤或样本加权。

## 推荐性能记录：R@20 / N@20

Cloth→Sport、Phone→Elec × 四个 backbone × 五种控制方式，**40/40 组单配置实验全部完成，0 运行、0 等待、0 失败。**远端队列于 2026-09-17 21:35:16（UTC+8）结束；2026-09-18 已逐项复核最终日志、结果 JSON 与汇总 CSV。40 个控制结果及 8 个完整 TriClass 参考值全部填齐，每格为 **R@20 / N@20**。

最后一列为 **ΔR = TriClass R@20 − 其余五种方式最高 R@20；ΔN = TriClass N@20 − 其余五种方式最高 N@20**，两项分别取最优，可能来自不同方式。记录绝对差值而非百分比，不是相对 Pure 或仅与简单合并比较。

| 任务 | Backbone | 单路 Direct Semantic | 单路用户级 G | 单路 Popularity | 三路简单合并（等权 RRF） | 三路可信排序（等权 Top-5） | TriClass 方法） R@20 / I |
|---|---|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | 0.0109 / 0.0090 | 0.0117 / 0.0102 | 0.0161 / 0.0147 | 0.0116 / 0.0112 | 0.0166 / 0.0141 | 0.0192 / |
| Cloth→Sport | UniCDR | 0.0071 / 0.0043 | 0.0108 / 0.0090 | 0.0410 / 0.0282 | 0.0083 / 0.0079 | 0.0253 / 0.0239 | 0.0561 / |
| Cloth→Sport | CD-CDR Normal | 0.0060 / 0.0056 | 0.0066 / 0.0080 | 0.0149 / 0.0146 | 0.0065 / 0.0070 | 0.0183 / 0.0149 | 0.0256 / 0.0250 |
| Cloth→Sport | CDRIB（确定性版） | 0.0116 / 0.0091 | 0.0086 / 0.0110 | 0.0246 / 0.0190 | 0.0146 / 0.0129 | 0.0154 / 0.0162 | 0.0224 / |
| Phone→Elec | EMCDR | 0.0338 / 0.0405 | 0.0405 / 0.0474 | 0.0403 / 0.0471 | 0.0403 / 0.0474 | 0.0404 / 0.0468 | 0.0406 / 0.0472 |
| Phone→Elec | UniCDR | 0.0027 / 0.0021 | 0.0303 / 0.0252 | 0.0520 / 0.0487 | 0.0394 / 0.0400 | 0.0485 / 0.0463 | 0.0619 / |
| Phone→Elec | CD-CDR Normal | 0.0008 / 0.0008 | 0.0334 / 0.0332 | 0.0407 / 0.0456 | 0.0401 / 0.0427 | 0.0465 / 0.0502 | 0.0479 / 0.0539 |
| Phone→Elec | CDRIB（确定性版） | 0.0239 / 0.0210 | 0.0368 / 0.0417 | 0.0412 / 0.0471 | 0.0399 / 0.0421 | 0.0443 / 0.0501 | 0.0502 / 0.0545 |

## 完整 TriClass 的来源与比较口径

- 新增完整 TriClass 列复用已完成结果，本次没有额外启动训练；仍为 40 组数量控制实验，加 8 个完整方法参考值。完整方法保留三分类可信排序、阈值过滤和逐样本置信度加权，可能不足每用户 5 个伪交互；前五列则固定每人 5 个、样本等权。因此完整方法列不是“相同最终数量、相同权重”的额外控制组。
- EMCDR、UniCDR、CD-CDR Normal：从 `src/triclass_runs/20260908/{model}_{task}.log` 的最终汇总中，提取与本轮相同 seed=999、整体伪监督权重和 eta 的结果，不重选参数。
- CDRIB：采用 `src/triclass_paired_overlap_runs/20260916_deterministic/CDRIB_{task}_r100_triclass_repeat0.result.json` 及同名训练日志。两个任务的重复运行均通过一致性检查；已核对与本轮的 28 份模型及训练基础代码、8 个数据文件和原始冷用户置信度缓存哈希一致，backbone 与伪监督超参数一致。Cloth→Sport 为 **0.0224 / 0.0197**，Phone→Elec 为 **0.0502 / 0.0545**，不混入历史非确定性版的 0.0256 / 0.0223 和 0.0520 / 0.0556，原主结果表不改动。
- 五种控制方式共用所有召回方式候选的并集作为负采样排除池；复用的完整 TriClass 使用原三路候选排除池。这一差异连同过滤、样本权重差异一并保留，最后一列是已有完整方法相对控制方式的性能差值，不宣称只隔离了某一个模块的贡献。

- 8 行最终差值均已补齐：**6 行双升**；Cloth→Sport / CDRIB 为 **-0.0022 / +0.0007**，Phone→Elec / EMCDR 为 **+0.0001 / -0.0002**。Phone→Elec / CDRIB 三路可信排序最终为 **0.0443 / 0.0501**，完整 TriClass 为 **0.0502 / 0.0545**，相对其余五种方式各指标最优值提升 **+0.0059 / +0.0044**。

### 完成状态（2026-09-18 核验）

两任务各 20 组控制实验均已完成。最后结束的 Phone→Elec / CDRIB 三路可信排序已取得最终汇总 **0.0443 / 0.0501**；不存在待填的中间结果。本次只整理记录，不改参数、不重新启动训练。

### 当前结果解读

- 完整 TriClass 相对其余五种方式各指标最优值：**6/8 行双升，2/8 行混合变化**；两个反例为 Cloth→Sport / CDRIB 和 Phone→Elec / EMCDR。
- 前五列的数量控制实验中，可信排序相对简单合并为 **7/8 行双升**；Phone→Elec / EMCDR 为 Recall 升、NDCG 降。
- 可信排序相对单路 Popularity 为 **3 行双升、3 行双降、2 行 Recall 升而 NDCG 降**。双升来自两个任务的 CD-CDR Normal 及 Phone→Elec / CDRIB；双降来自两个任务的 UniCDR 及 Cloth→Sport / CDRIB。
- 完整方法包含过滤与置信度加权，且沿用原负采样排除池；因此新增完整方法列不是只改变排序的等权控制组。保留所有反例，不作多种子显著性结论。

### 本次回传与核验

整轮回传于 **2026-09-17 21:35:54（UTC+8）** 完成。本机 `src/triclass_retrieval_runs/20260916/remote_results/` 已有 **40 份训练日志 + 40 份最终结果 JSON**，另含最终 `performance.csv`、`status.json` 等文件。2026-09-18 重新比较远端与本机的这 82 个日志、结果和汇总文件，SHA-256 全部一致；远端原件保留。应读取最终汇总，不再使用 39/40 时的 `progress_snapshot.json` 旧快照。

### 五种控制方式与完整方法

- **单路 Direct Semantic**：仅按用户目标域兴趣语义与目标物品语义相似度召回，按该顺序选择 Top-5。
- **单路用户级 G**：仅按冻结用户级 G 映射后的协同匹配分数召回，按该顺序选择 Top-5。
- **单路 Popularity**：仅按目标域非重叠用户的训练交互热度召回，按该顺序选择 Top-5。
- **三路简单合并**：沿用原三路去重后的候选集合，使用等权 RRF 合并排序，常数为 60，再取 Top-5；不使用学习得到的可信分数。
- **三路可信排序（等权 Top-5）**：在与简单合并完全相同的候选集合中，按 `p_hit + eta * p_near` 取 Top-5。三分类器及其输出概率均复用原缓存，不重新训练。
- **TriClass（完整方法）**：原三路候选经三分类可信评分、阈值过滤和 Top-K 选择后，用置信度进行逐样本 loss 加权；本列复用已完成的完整方法结果，不等同于第五列。

### 数量与训练控制

- **不固定为 150 个。** 对每位用户，以原三路候选去重后的实际数量 M_u 为准，各单路召回 Top-M_u；三路简单合并与可信排序直接复用该原候选集合。零填充和重复物品不计数。
- 冷用户候选数：Cloth→Sport 为 137–150 个，均值 149.25；Phone→Elec 为 121–150 个，均值 136.46。同一任务、同一用户在五种方式中的候选数量完全一致。
- 五种方式最终均覆盖全部冷用户，每人固定 5 个伪正样本，逐样本 loss 权重均为 1。**整体 `pseudo_loss_weight` 仍保留，并不是把整体伪监督系数设为 1。**
- 同一任务与 backbone 的五种方式固定相同的 backbone 配置、整体伪监督权重、seed=999 和采样设置，不额外搜索。可信排序中的 eta 使用对应原 TriClass 固定配置。
- 各方式共用负采样排除集合，即该用户所有对比方式候选集合的并集，避免负采样池差异干扰比较。构建过程中不使用冷用户目标域验证或测试交互。
- CDRIB 五种方式统一采用确定性图传播版本，记录时不可混入历史非确定性 CDRIB 的结果。既有主结果表不改动。

### 文件与后续登记

- 实验配置：`src/configs/model/TriClassRetrievalBudget.yaml`。
- 远端训练目录：`10.32.80.5:/home/guqiwen/CDRec/src/triclass_retrieval_runs/20260916/`。

- 队列与汇总：上述目录内的 `status.json`、`performance.csv`；逐任务日志为 `{model}_{task}_{variant}.log`，最终结果为对应的 `.result.json`。
- variant 对应关系：`semantic`、`user_g`、`popularity`、`union_rrf`、`trusted`，与表中五列顺序一致。
- 本机协议与缓存：`/data/guqiwen/CDRec/src/triclass_retrieval_runs/20260916/`；整轮日志与结果已回传其 `remote_results/` 子目录，并完成文件哈希核验。
- 前五种控制方式后续仅凭已完成任务的最终审计结果回填，不把空白当作 0，也不以中途 epoch 指标或原主表数值替代本轮结果。新增完整 TriClass 列按上方注明的已完成日志与确定性结果复用，来源单独标注。

# 完整重叠监督预算：Pure / TriClass 配套实验（已完成，2026-09-18 核验）

## CDRIB 一致性重跑

独立确定性重跑已全部完成：Cloth→Sport、Phone→Elec × 五档预算 × Pure/TriClass，共 **20 次主实验**，另对 100% 的四组配置各独立重复一次，共 **24/24 次训练完成**。

Pure 与 TriClass 共用 `CDRIB_Grounded_TriClass_Deterministic`，同预算使用相同数据、缓存及 seed=999，只切换伪监督损失。保留原数学运算与参数，将非确定性 GPU 稀疏矩阵乘法替换为已验证的确定性稀疏批乘；固定线程、cuBLAS 设置，并保存代码快照、配置及输入哈希。原有 9 项测试、真实数据短程重复测试和跨 GPU 短程核验记录保留。

2026-09-18 重新检查，**四组 100% 主实验与独立重复均完全一致，4/4 项整轮检查通过**，包括逐 epoch 参数/随机状态轨迹、最终权重、停止轮次、验证/测试指标及输入与代码哈希。该保证针对已验证的 100% 配置及环境；20%–80% 各配置本轮各运行一次，不把它们写成已经逐组重复验证。

下表 CDRIB 的 **10/10 组配套结果全部采用本轮确定性测量**，不再混入旧值。其余 backbone 未重跑。输出目录为 `src/triclass_paired_overlap_runs/20260916_deterministic/`，原非确定性测量及原始 CSV 保留，不改写历史结果。

## CDRIB 完成状态（2026-09-18 核验）

队列最后更新于 **2026-09-17 19:43:32（UTC+8）：24/24 次训练、20/20 次主实验、10/10 组配套对照完成，0 运行、0 等待、0 失败**。本次补齐此前尚标为旧值的 9 组 CDRIB 结果。

100% 预算：Cloth→Sport 为 Pure **0.0277 / 0.0257**、TriClass **0.0224 / 0.0197**，双降；Phone→Elec 为 Pure **0.0425 / 0.0478**、TriClass **0.0502 / 0.0545**，双升。两方向 Pure 和 TriClass 的独立重复均通过；不能因结果可复现而将下降写成增益。

日志与结果命名为 `CDRIB_{ClothSport或PhoneElec}_r{020/040/060/080/100}_{pure或triclass}_repeat0.log` 及同名 `.result.json`、`.trace.jsonl`；100% 的重复运行使用 `repeat1`。

## 要验证什么

检验随着可用重叠目标监督减少，Pure 是否退化，以及同预算下 TriClass 是否保持增益、退化是否更缓。这是待检验假设，不保证单调下降或每组插件都更好。它与下节“只减少可信评估器标注量”的旧实验不同。

## 数据与公平对照协议

1. 保留原先冷启动验证/测试用户、交互与目标物品全集；源域训练历史全部不变。
2. 重叠监督预算设为原训练重叠用户的 20%、40%、60%、80%、100%。按固定 seed=999，在原可信 Train/Validation/Test 三个用户组内分别取嵌套子集，保持用户的可信评估角色不变。
3. 被移出的重叠用户保留源域历史，转为额外源域冷用户；其目标训练交互及目标用户身份完全移除。通过独立数据目录重映射 ID，避免仅改 loss 权重但监督仍从图或历史进入模型。
4. 原配套运行在同一比例下使用完全相同的数据和模型类，区别仅为是否启用伪监督损失，两者均重新训练。展示例外：按用户于 2026-09-16 的要求，Phone→Elec / UniCDR 的 100% 行改为复用“结果总表”的完整监督结果；该行不是本轮重跑测量，20%–80% 保持原配套测量值。
5. 冻结原语义、目标域非重叠教师、用户级 G 和三路候选：它们不包含原重叠用户的目标边，且源域原始交互未变，故可合法复用。旧投票证据全部覆盖重算；分类器只使用当前保留的重叠用户，重新验证阈值。
6. 对可信质量另固定共同测试用户：Cloth→Sport 125 人、Phone→Elec 438 人，均不进入可信分类器训练或投票参考；各比例均保留这些用户作为可信测试角色。它们不是推荐任务的冷启动评测用户。
7. seed=999，backbone 设置与各自 λ/η 沿用 TriClass 所选配置，不按比例重新搜索参数；Pure 仅关闭插件。无需重新调用 API。

这是"隐藏目标历史"的监督预算实验，总目标训练边数也会减少；不是保留所有目标交互、只隐藏跨域 ID 对应关系的另一种协议。

## 实际重叠用户数

| 名义保留比例 | Cloth→Sport | Phone→Elec |
|---|---|---|
| 20% | 625 | 2,188 |
| 40% | 1,250 | 4,377 |
| 60% | 1,876 | 6,567 |
| 80% | 2,501 | 8,756 |
| 100% | 3,128 | 10,946 |

每个原用户组内向下取整，因此与名义比例可能相差 1–3 人，实际比例和全部保留 ID 已保存。

## 运行与结果登记

原配套实验的 **10/10 次缓存构建与审计、80/80 次训练**已于 2026-09-16 完成，最终日志与 CSV 一致。本表综合原非 CDRIB 配套结果、本次 CDRIB 确定性重跑，以及一处按用户要求引用的主表结果，**40/40 行均已填齐**。

每格保持 **R@20 / N@20**；Δ 为 **TriClass − Pure** 的绝对差值，状态列按日志四位小数标注双升、双降或单项变化。CDRIB 10 行统一使用确定性版本。

**既有展示例外保持不变**：Phone→Elec / UniCDR / 100% 按用户要求复用主表，Pure=0.0537 / 0.0619、TriClass=0.0619 / 0.0689，Δ=+0.0082 / +0.0070；该行不是本轮独立配套测量。原配套 Pure=0.0495 / 0.0598、TriClass=0.0619 / 0.0689 的日志与 CSV 保留。引用来源：`src/runGroundedBackbonePhoneElec_2_UniCDR.log` 与 `src/triclass_runs/20260908/UniCDR_PhoneElec.log`，20%–80% 不作替换。

| 数据集 | Backbone | 保留比例 | Pure R@20 / N@20 | TriClass R@20 / N@20 | ΔR / ΔN | 状态 |
|---|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | 20% | 0.0089 / 0.0104 | 0.0100 / 0.0102 | +0.0011 / -0.0002 | Recall 升、NDCG 降 |
| Cloth→Sport | EMCDR | 40% | 0.0157 / 0.0164 | 0.0163 / 0.0178 | +0.0006 / +0.0014 | 双升 |
| Cloth→Sport | EMCDR | 60% | 0.0178 / 0.0178 | 0.0182 / 0.0178 | +0.0004 / 0.0000 | Recall 升、NDCG 持平 |
| Cloth→Sport | EMCDR | 80% | 0.0138 / 0.0158 | 0.0178 / 0.0160 | +0.0040 / +0.0002 | 双升 |
| Cloth→Sport | EMCDR | 100% | 0.0177 / 0.0182 | 0.0192 / 0.0181 | +0.0015 / -0.0001 | Recall 升、NDCG 降 |
| Cloth→Sport | UniCDR | 20% | 0.0175 / 0.0143 | 0.0153 / 0.0156 | -0.0022 / +0.0013 | Recall 降、NDCG 升 |
| Cloth→Sport | UniCDR | 40% | 0.0239 / 0.0203 | 0.0281 / 0.0230 | +0.0042 / +0.0027 | 双升 |
| Cloth→Sport | UniCDR | 60% | 0.0465 / 0.0408 | 0.0277 / 0.0227 | -0.0188 / -0.0181 | 双降 |
| Cloth→Sport | UniCDR | 80% | 0.0462 / 0.0384 | 0.0418 / 0.0390 | -0.0044 / +0.0006 | Recall 降、NDCG 升 |
| Cloth→Sport | UniCDR | 100% | 0.0425 / 0.0352 | 0.0561 / 0.0493 | +0.0136 / +0.0141 | 双升 |
| Cloth→Sport | CD-CDR Normal | 20% | 0.0126 / 0.0138 | 0.0163 / 0.0180 | +0.0037 / +0.0042 | 双升 |
| Cloth→Sport | CD-CDR Normal | 40% | 0.0151 / 0.0148 | 0.0220 / 0.0214 | +0.0069 / +0.0066 | 双升 |
| Cloth→Sport | CD-CDR Normal | 60% | 0.0131 / 0.0162 | 0.0234 / 0.0244 | +0.0103 / +0.0082 | 双升 |
| Cloth→Sport | CD-CDR Normal | 80% | 0.0159 / 0.0180 | 0.0170 / 0.0196 | +0.0011 / +0.0016 | 双升 |
| Cloth→Sport | CD-CDR Normal | 100% | 0.0152 / 0.0178 | 0.0256 / 0.0250 | +0.0104 / +0.0072 | 双升 |

| 数据集 | Backbone | 保留比例 | Pure R@20 / N@20 | TriClass R@20 / N@20 | ΔR / ΔN | 状态 |
|---|---|---|---|---|---|---|
| Cloth→Sport | CDRIB（确定性版） | 20% | 0.0167 / 0.0155 | 0.0177 / 0.0167 | +0.0010 / +0.0012 | 双升 |
| Cloth→Sport | CDRIB（确定性版） | 40% | 0.0289 / 0.0256 | 0.0217 / 0.0164 | -0.0072 / -0.0092 | 双降 |
| Cloth→Sport | CDRIB（确定性版） | 60% | 0.0243 / 0.0218 | 0.0201 / 0.0182 | -0.0042 / -0.0036 | 双降 |
| Cloth→Sport | CDRIB（确定性版） | 80% | 0.0186 / 0.0170 | 0.0217 / 0.0206 | +0.0031 / +0.0036 | 双升 |
| Cloth→Sport | CDRIB（确定性版） | 100% | 0.0277 / 0.0257 | 0.0224 / 0.0197 | -0.0053 / -0.0060 | 双降；整轮重复一致 |
| Phone→Elec | EMCDR | 20% | 0.0357 / 0.0456 | 0.0369 / 0.0451 | +0.0012 / -0.0005 | Recall 升、NDCG 降 |
| Phone→Elec | EMCDR | 40% | 0.0376 / 0.0421 | 0.0371 / 0.0418 | -0.0005 / -0.0003 | 双降 |
| Phone→Elec | EMCDR | 60% | 0.0388 / 0.0486 | 0.0389 / 0.0484 | +0.0001 / -0.0002 | Recall 升、NDCG 降 |
| Phone→Elec | EMCDR | 80% | 0.0382 / 0.0468 | 0.0379 / 0.0466 | -0.0003 / -0.0002 | 双降 |
| Phone→Elec | EMCDR | 100% | 0.0405 / 0.0471 | 0.0406 / 0.0472 | +0.0001 / +0.0001 | 双升 |
| Phone→Elec | UniCDR | 20% | 0.0333 / 0.0362 | 0.0483 / 0.0550 | +0.0150 / +0.0188 | 双升 |
| Phone→Elec | UniCDR | 40% | 0.0340 / 0.0404 | 0.0533 / 0.0600 | +0.0193 / +0.0196 | 双升 |
| Phone→Elec | UniCDR | 60% | 0.0415 / 0.0481 | 0.0578 / 0.0640 | +0.0163 / +0.0159 | 双升 |
| Phone→Elec | UniCDR | 80% | 0.0446 / 0.0539 | 0.0601 / 0.0661 | +0.0155 / +0.0122 | 双升 |
| Phone→Elec | UniCDR | 100% | 0.0537 / 0.0619 | 0.0619 / 0.0689 | +0.0082 / +0.0070 | 双升；引用主表 |
| Phone→Elec | CD-CDR Normal | 20% | 0.0281 / 0.0327 | 0.0413 / 0.0469 | +0.0132 / +0.0142 | 双升 |
| Phone→Elec | CD-CDR Normal | 40% | 0.0321 / 0.0353 | 0.0411 / 0.0482 | +0.0090 / +0.0129 | 双升 |
| Phone→Elec | CD-CDR Normal | 60% | 0.0344 / 0.0407 | 0.0406 / 0.0487 | +0.0062 / +0.0080 | 双升 |
| Phone→Elec | CD-CDR Normal | 80% | 0.0316 / 0.0339 | 0.0476 / 0.0518 | +0.0160 / +0.0179 | 双升 |
| Phone→Elec | CD-CDR Normal | 100% | 0.0316 / 0.0355 | 0.0479 / 0.0539 | +0.0163 / +0.0184 | 双升 |
| Phone→Elec | CDRIB（确定性版） | 20% | 0.0370 / 0.0433 | 0.0453 / 0.0484 | +0.0083 / +0.0051 | 双升 |
| Phone→Elec | CDRIB（确定性版） | 40% | 0.0373 / 0.0438 | 0.0452 / 0.0525 | +0.0079 / +0.0087 | 双升 |
| Phone→Elec | CDRIB（确定性版） | 60% | 0.0387 / 0.0461 | 0.0431 / 0.0479 | +0.0044 / +0.0018 | 双升 |
| Phone→Elec | CDRIB（确定性版） | 80% | 0.0379 / 0.0455 | 0.0456 / 0.0499 | +0.0077 / +0.0044 | 双升 |
| Phone→Elec | CDRIB（确定性版） | 100% | 0.0425 / 0.0478 | 0.0502 / 0.0545 | +0.0077 / +0.0067 | 双升；整轮重复一致 |

**固定可信测试用户的质量（10/10 完成）**

以下结果来自 `confidence.csv` 和各方向、各比例的 `confidence_*.json`，每个方向各比例始终使用同一批可信测试用户：Cloth→Sport 125 人、Phone→Elec 438 人。这些用户未参与可信分类器训练或投票参考，与推荐评估中的冷启动用户不同。可信训练人数随预算变化；不是把旧"重叠标注量敏感性"表直接复制过来。

| 数据集 | 保留比例 | 可信训练 / 固定审计人数 | Hit AUPRC ↑ | Hit+Near AUPRC ↑ | 多类 Brier ↓ | ECE-15 ↓ |
|---|---|---|---|---|---|---|
| Cloth→Sport | 20% | 375 / 125 | 0.0284 | 0.2570 | 0.117198 | 0.008171 |
| Cloth→Sport | 40% | 750 / 125 | 0.0256 | 0.2622 | 0.116943 | 0.006598 |
| Cloth→Sport | 60% | 1125 / 125 | 0.0262 | 0.2601 | 0.117074 | 0.006396 |
| Cloth→Sport | 80% | 1500 / 125 | 0.0281 | 0.2620 | 0.116889 | 0.006204 |
| Cloth→Sport | 100% | 1876 / 125 | 0.0284 | 0.2625 | 0.116815 | 0.005823 |
| Phone→Elec | 20% | 1313 / 438 | 0.0654 | 0.5362 | 0.279862 | 0.008048 |
| Phone→Elec | 40% | 2626 / 438 | 0.0711 | 0.5361 | 0.279859 | 0.008237 |
| Phone→Elec | 60% | 3940 / 438 | 0.0735 | 0.5374 | 0.279739 | 0.007937 |
| Phone→Elec | 80% | 5253 / 438 | 0.0729 | 0.5375 | 0.279727 | 0.007555 |
| Phone→Elec | 100% | 6567 / 438 | 0.0726 | 0.5369 | 0.279757 | 0.007093 |

Hit AUPRC 衡量命中类概率对真实命中的排序；Hit+Near AUPRC 将命中与偏好相邻合为正类，使用两类概率之和。Brier 为三类概率平方误差之和的样本均值；ECE-15 按最大类别概率分 15 档，比较预测置信度与分类正确率。后两项越低越好，但标签不平衡下，较低 ECE 不能单独证明伪交互高质量。不同数据集的基准命中率不同，不直接把 AUPRC 数值横向当成模型优劣。

## 完整结果解读（采用确定性 CDRIB）

以下统计按上表当前 40 行重算，包含已注明来源的 Phone→Elec / UniCDR 100% 主表引用，不再混用旧 CDRIB 结果。

- **40 行：27 行双升、6 行双降、4 行 Recall 升/NDCG 降、2 行 Recall 降/NDCG 升、1 行 Recall 升/NDCG 持平。** Recall 提升 32/40，NDCG 提升 29/40；全部结果保留。
- **Pure 的稀疏监督退化有端点证据**：八个"方向 × backbone"组合在 20% 相比 100% 时均为 R/N 双降，但中间各档不保证单调。
- **20% 预算下 5/8 行双升**，另有 2 行 Recall 升/NDCG 降、1 行 Recall 降/NDCG 升。Cloth→Sport / CD-CDR Normal，以及 Phone→Elec 的 UniCDR、CD-CDR Normal、确定性 CDRIB，在五档均双升。
- **同预算优于 Pure，不等于随预算减少退化更缓。** Phone→Elec / UniCDR 的 100%→20% 相对 R/N 降幅为 Pure 38.0% / 41.5%、TriClass 22.0% / 20.2%，其中 100% 引用主表。确定性 Phone→Elec / CDRIB 为 Pure 12.9% / 9.4%、TriClass 9.8% / 11.2%，只在 Recall 的端点降幅更缓，不能延用旧版本"两项均更缓"的结论。
- **反例均保留**：Cloth→Sport / UniCDR 在 60% 双降；确定性 Cloth→Sport / CDRIB 在 40%、60%、100% 双降；Phone→Elec / EMCDR 在 40%、80% 双降。
- **可信质量变化有限、非严格单调**：Cloth→Sport 的 Hit AUPRC 为 0.0256–0.0284、Hit+Near AUPRC 为 0.2570–0.2625；Phone→Elec 分别为 0.0654–0.0735、0.5361–0.5375。这些是固定审计用户上的指标，不能替代推荐性能。

固定 seed=999 的结果及确定性复现检查，不等于跨随机种子的显著性结论。本实验减少的是可用重叠目标监督，不是只减少分类器标注量。

## 输出与复核

- 原配套目录：`src/triclass_paired_overlap_runs/20260914/`；确定性 CDRIB 目录：`src/triclass_paired_overlap_runs/20260916_deterministic/`。CDRIB 当前值从后者读取，其他 backbone 从前者读取；主表引用另见 `presentation_overrides.json`。
- `paired_results.csv`：逐模型、逐预算的 Pure/TriClass 及成对差值。
- `performance.csv`：80 个训练任务的指标、状态和日志路径。
- `confidence.csv`：固定可信测试用户上的质量指标。
- `preparation/`：保留用户、数据映射、原数据和新数据哈希；`data/`：独立的受限训练视图及伪监督缓存。
- `status.json`、`coordinator.log`、`service.log`：队列与进程状态。
- 新增脚本/配置：`src/tools/run_triclass_paired_overlap.py`、`src/configs/model/TriClassPairedOverlap.yaml`；测试：`src/tools/test_triclass_paired_overlap.py`。

- 已通过新协议的 4 项测试及原 TriClass 11 项测试；后者包含四个 backbone 的前向与反向测试。另外，两个真实 20% 预算数据上的四个 backbone 共 8 次单批前向/反向检查也全部通过。原模型、benchmark 和原始数据未修改。

# TriClass 重叠标注量敏感性实验（已完成，2026-09-13 汇总）

**已完成：32/32 组新增推荐训练、10/10 组置信度评估，0 失败。** 100% 设置复用原 TriClass 的 8 组结果，共 40 组推荐结果。队列于 2026-09-12 10:27（北京时间）正常结束。

## 实验定义与比例口径

本实验考察：用于 TriClass 可信评估的重叠用户标注减少后，置信度质量与插件推荐性能如何变化。

- **20%、40%、60%、80%、100% 指原 TriClass 训练重叠用户池的保留比例。** 原训练池约占全部重叠用户的 60%，所以对应全部重叠用户的约 12%、24%、36%、48%、60%。
- 训练子集嵌套，固定随机种子 999；保留比例越大，包含的训练用户越多。Cloth→Sport 的验证/测试重叠用户固定为 625/627 人，Phone→Elec 固定为 2,189/2,190 人。
- 随比例重建重叠投票证据，重新训练三分类器，并按验证集确定筛选阈值、生成新的冷用户可信伪监督。
- 现有 LLM 兴趣和语义向量、目标域 LightGCN 与 G 的缓存复用。三路召回方式、标签定义和 backbone 原始训练数据保持不变。
- 每个"数据集 × backbone"固定使用完整 TriClass 的最优参数；每个比例运行一个配置，不重新搜索。100% 推荐结果复用 20260908 的原始 TriClass 完成日志。
- **这轮结果支持"可信评估对重叠标注量的敏感性"分析。Backbone 的可用重叠监督未同步减少，因此不能直接作为整个推荐系统在不同总体重叠用户比例下的实验。**

| 训练池保留比例 | Cloth→Sport：训练人数（占全部重叠用户） | Phone→Elec：训练人数（占全部重叠用户） |
|---|---|---|
| 20% | 375 人（11.99%） | 1313 人（12.00%） |
| 40% | 750 人（23.98%） | 2626 人（23.99%） |
| 60% | 1125 人（35.97%） | 3940 人（35.99%） |
| 80% | 1500 人（47.95%） | 5253 人（47.99%） |
| 100% | 1876 人（59.97%） | 6567 人（59.99%） |

## 推荐性能：R@20 / N@20

每格第一行为 **R@20 / N@20**；括号内为相对同一行 **Pure Backbone 的 ΔR / ΔN**。Pure 来自本页当前代码的基线记录，100% 是原 TriClass。展示全部比例结果，不根据本轮结果替换主结果总表中的 TriClass 配置。

| 任务 | Backbone | Pure Backbone | 20% | 40% | 60% | 80% | 100%（ |
|---|---|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | 0.0177 / 0.0182 | 0.0179 / 0.0174 (+0.0002 / -0.0008) | 0.0195 / 0.0193 (+0.0018 / +0.0011) | 0.0209 / 0.0202 (+0.0032 / +0.0020) | 0.0196 / 0.0185 (+0.0019 / +0.0003) | 0.0192 / (+0.0015 -0.0001) |
| Cloth→Sport | UniCDR | 0.0425 / 0.0352 | 0.0455 / 0.0388 (+0.0030 / +0.0036) | 0.0511 / 0.0427 (+0.0086 / +0.0075) | 0.0507 / 0.0443 (+0.0082 / +0.0091) | 0.0564 / 0.0509 (+0.0139 / +0.0157) | 0.0561 / (+0.0136 +0.0141) |
| Cloth→Sport | CD-CDR Normal | 0.0152 / 0.0178 | 0.0163 / 0.0181 (+0.0011 / +0.0003) | 0.0221 / 0.0227 (+0.0069 / +0.0049) | 0.0222 / 0.0235 (+0.0070 / +0.0057) | 0.0224 / 0.0236 (+0.0072 / +0.0058) | 0.0256 / 0.0250 (+0.0104 +0.0072 |
| Cloth→Sport | CDRIB | 0.0198 / 0.0167 | 0.0212 / 0.0186 (+0.0014 / +0.0019) | 0.0216 / 0.0197 (+0.0018 / +0.0030) | 0.0203 / 0.0201 (+0.0005 / +0.0034) | 0.0184 / 0.0168 (-0.0014 / +0.0001) | 0.0256 / 0.0223 (+0.0058 +0.0056 |
| Phone→Elec | EMCDR | 0.0405 / 0.0471 | 0.0401 / 0.0467 (-0.0004 / -0.0004) | 0.0401 / 0.0466 (-0.0004 / -0.0005) | 0.0402 / 0.0468 (-0.0003 / -0.0003) | 0.0400 / 0.0467 (-0.0005 / -0.0004) | 0.0406 / 0.0472 (+0.0001 +0.0001) |

| 任务 | Backbone | Pure Backbone | 20% | 40% | 60% | 80% | 100%（全 |
|---|---|---|---|---|---|---|---|
| Phone→Elec | UniCDR | 0.0537 / 0.0619 | 0.0612 / 0.0665 (+0.0075 / +0.0046) | 0.0631 / 0.0678 (+0.0094 / +0.0059) | 0.0613 / 0.0678 (+0.0076 / +0.0059) | 0.0585 / 0.0651 (+0.0048 / +0.0032) | 0.0619 / (+0.008 +0.0070 |
| Phone→Elec | CD-CDR Normal | 0.0316 / 0.0355 | 0.0452 / 0.0513 (+0.0136 / +0.0158) | 0.0415 / 0.0485 (+0.0099 / +0.0130) | 0.0468 / 0.0513 (+0.0152 / +0.0158) | 0.0434 / 0.0499 (+0.0118 / +0.0144) | 0.0479 / 0.0539 (+0.0163 +0.0184) |
| Phone→Elec | CDRIB | 0.0384 / 0.0477 | 0.0453 / 0.0504 (+0.0069 / +0.0027) | 0.0500 / 0.0546 (+0.0116 / +0.0069) | 0.0451 / 0.0520 (+0.0067 / +0.0043) | 0.0493 / 0.0536 (+0.0109 / +0.0059) | 0.0520 / 0.0556 (+0.0136 +0.0079 |

## 置信度质量：固定重叠测试用户

以下指标在固定的、未参与分类器训练和阈值选择的重叠测试用户上计算。CE、Brier、ECE15 越低越好；Hit AUPRC 与 Supported AUPRC 越高越好。Supported 表示 Hit 或 Near。ECE15 是三分类最大概率与分类正确率之间的分箱误差，不能单独代替稀疏 Hit 类的质量指标。

| 任务 | 训练池保留比例 | CE | Brier | ECE15 | Hit AUPRC | Supported AUPRC |
|---|---|---|---|---|---|---|
| Cloth→Sport | 20% | 0.222119 | 0.116244 | 0.006804 | 0.030652 | 0.242067 |
| Cloth→Sport | 40% | 0.221663 | 0.116011 | 0.007524 | 0.031926 | 0.248164 |
| Cloth→Sport | 60% | 0.221585 | 0.116054 | 0.008114 | 0.036981 | 0.248017 |
| Cloth→Sport | 80% | 0.221363 | 0.115955 | 0.006834 | 0.038351 | 0.248314 |
| Cloth→Sport | 100% | 0.221018 | 0.115809 | 0.006523 | 0.046697 | 0.250183 |
| Phone→Elec | 20% | 0.433879 | 0.278043 | 0.009043 | 0.062430 | 0.538167 |
| Phone→Elec | 40% | 0.433875 | 0.278139 | 0.008900 | 0.064267 | 0.537659 |
| Phone→Elec | 60% | 0.433744 | 0.278044 | 0.008828 | 0.064759 | 0.538745 |
| Phone→Elec | 80% | 0.433615 | 0.277971 | 0.008154 | 0.066780 | 0.539335 |
| Phone→Elec | 100% | 0.433582 | 0.277934 | 0.007722 | 0.067720 | 0.539324 |

## 筛选后的伪监督质量与覆盖率

以下表格仍是**固定重叠测试用户上的诊断结果**，不是冷用户的真实命中率。rho = p_hit + eta × p_near；每个用户最多选择 5 个过阈值候选，未达到数量时不补齐。阈值由验证集选择。Hit Precision 与 Hit+Near Precision 按选中的候选对统计；用户覆盖率表示至少选中一个候选的测试用户比例。

▼ Cloth→Sport：全部 15 组置信筛选结果

| 保留比例 | eta | 阈值 | Hit Precision | Hit+Near Precision | Near 占比 | 用户覆盖率 | 选中 |
|---|---|---|---|---|---|---|---|
| 20% | 0.0 | 0.05 | 12.05% | 22.80% | 10.75% | 33.97% | 307 |
| 20% | 0.25 | 0.1 | 6.17% | 36.27% | 30.09% | 50.88% | 648 |
| 20% | 0.5 | 0.2 | 6.07% | 40.26% | 34.19% | 29.51% | 313 |
| 40% | 0.0 | 0.05 | 11.54% | 29.49% | 17.95% | 26.95% | 234 |
| 40% | 0.25 | 0.1 | 5.77% | 37.82% | 32.05% | 47.69% | 624 |
| 40% | 0.5 | 0.2 | 5.14% | 43.71% | 38.57% | 29.35% | 350 |
| 60% | 0.0 | 0.05 | 12.13% | 29.41% | 17.28% | 27.59% | 272 |
| 60% | 0.25 | 0.1 | 6.14% | 38.11% | 31.97% | 48.80% | 635 |
| 60% | 0.5 | 0.2 | 6.07% | 44.80% | 38.73% | 29.82% | 346 |
| 80% | 0.0 | 0.05 | 10.76% | 31.10% | 20.35% | 33.97% | 344 |
| 80% | 0.25 | 0.1 | 6.11% | 38.59% | 32.47% | 54.86% | 736 |
| 80% | 0.5 | 0.2 | 6.55% | 42.23% | 35.68% | 35.89% | 412 |
| 100% | 0.0 | 0.05 | 12.33% | 29.86% | 17.53% | 34.93% | 365 |
| 100% | 0.25 | 0.1 | 6.86% | 37.74% | 30.88% | 56.78% | 787 |

| 保留比例 | eta | 阈值 | Hit Precision | Hit+Near Precision | Near 占比 | 用户覆盖率 | 选中 |
|---|---|---|---|---|---|---|---|
| 100% | 0.5 | 0.2 | 7.53% | 41.42% | 33.89% | 38.60% | 478 |

▼ Phone→Elec：全部 15 组置信筛选结果

| 保留比例 | eta | 阈值 | Hit Precision | Hit+Near Precision | Near 占比 | 用户覆盖率 | 选中 |
|---|---|---|---|---|---|---|---|
| 20% | 0.0 | 0.1 | 21.28% | 57.07% | 35.79% | 31.92% | 827 |
| 20% | 0.25 | 0.2 | 9.98% | 62.09% | 52.11% | 78.77% | 3358 |
| 20% | 0.5 | 0.4 | 14.73% | 61.45% | 46.72% | 41.96% | 1188 |
| 40% | 0.0 | 0.1 | 21.62% | 57.92% | 36.30% | 33.52% | 865 |
| 40% | 0.25 | 0.2 | 10.43% | 60.48% | 50.05% | 75.71% | 3115 |
| 40% | 0.5 | 0.4 | 15.56% | 58.85% | 43.29% | 38.26% | 1028 |
| 60% | 0.0 | 0.1 | 22.39% | 58.34% | 35.96% | 29.00% | 737 |
| 60% | 0.25 | 0.2 | 9.57% | 62.56% | 53.00% | 74.75% | 3136 |
| 60% | 0.5 | 0.4 | 15.72% | 61.87% | 46.15% | 35.39% | 986 |
| 80% | 0.0 | 0.1 | 22.28% | 58.26% | 35.99% | 30.82% | 817 |
| 80% | 0.25 | 0.2 | 10.18% | 62.94% | 52.76% | 75.39% | 3154 |
| 80% | 0.5 | 0.4 | 17.23% | 61.85% | 44.62% | 35.71% | 975 |
| 100% | 0.0 | 0.1 | 22.81% | 59.77% | 36.97% | 30.09% | 798 |
| 100% | 0.25 | 0.2 | 10.36% | 63.17% | 52.81% | 74.93% | 3234 |
| 100% | 0.5 | 0.4 | 16.41% | 61.47% | 45.06% | 35.84% | 981 |

## 本轮固定插件参数

所有比例均固定 seed=999。eta 对应 near_support_weight；以下两项来自原完整 TriClass 的最优配置。

| 任务 | Backbone | pseudo_loss_weight | near_support_weight（eta） |
|---|---|---|---|
| Cloth→Sport | EMCDR | 0.1 | 0.25 |
| Cloth→Sport | UniCDR | 0.1 | 0.0 |
| Cloth→Sport | CD-CDR Normal | 1.0 | 0.0 |
| Cloth→Sport | CDRIB | 0.1 | 0.25 |
| Phone→Elec | EMCDR | 0.1 | 0.0 |
| Phone→Elec | UniCDR | 1.0 | 0.5 |
| Phone→Elec | CD-CDR Normal | 1.0 | 0.25 |
| Phone→Elec | CDRIB | 1.0 | 0.5 |

## 结果解读

1. **增加可信评估训练用户能够提高 Hit 排序质量。** Cloth→Sport 的 Hit AUPRC 从 0.030652 提高到 0.046697，Phone→Elec 从 0.062430 提高到 0.067720；两项任务的 Hit AUPRC 均随这五个比例递增。
2. **Cloth→Sport 对减少重叠标注更敏感。** UniCDR 从 20% 的 0.0455 / 0.0388 提高到 100% 的 0.0561 / 0.0493；CD-CDR Normal 从 0.0163 / 0.0181 提高到 0.0256 / 0.0250。
3. **Phone→Elec 的置信度排序能力较稳定。** 20% 训练池已有 1,313 名标注重叠用户，Hit AUPRC 为 0.062430，接近完整训练池 6,567 人时的 0.067720；但推荐性能仍随筛选集合和 backbone 而波动。
4. **推荐性能不严格单调。** Cloth→Sport 的 EMCDR 在 60% 达到 0.0209 / 0.0202，UniCDR 在 80% 达到 0.0564 / 0.0509，均高于对应 100% 结果。Phone→Elec UniCDR 在 40% 的 Recall 更高，但 NDCG 仍低于 100%。
5. 当前为固定单种子观察；局部更高不能推出“减少标注必然更好”。如果后续论文要验证整体重叠监督稀缺，还需同步限制 backbone 的训练重叠监督，并运行相同限制下的 Pure 对照。

## 结果与日志来源

- 推荐结果：`/data/guqiwen/CDRec/src/triclass_overlap_ratio_runs/20260911_full/performance.csv`

- 置信度及筛选结果：`/data/guqiwen/CDRec/src/triclass_overlap_ratio_runs/20260911_full/confidence.csv`
- 完成状态及逐任务日志路径：`/data/guqiwen/CDRec/src/triclass_overlap_ratio_runs/20260911_full/status.json`
- 队列日志：`/data/guqiwen/CDRec/src/triclass_overlap_ratio_runs/20260911_full/coordinator.log`
- 逐任务训练日志：同目录下 `train_{model}_{task}_r020/r040/r060/r080.log`。
- 100% 复用日志：`/data/guqiwen/CDRec/src/triclass_runs/20260908/{model}_{task}.log`
- 实验入口：`/data/guqiwen/CDRec/src/tools/run_triclass_overlap_ratio_study.py`

## v3 可信校准函数消融（进行中）

本表验证 v3 动态置信度组合方式是否有效。所有数值均为 **R@20 / N@20**。每个任务与 Backbone 固定使用原 v3 的最优 `v3_setting` 及其他配置，只改变动态置信度的组合方式；"—（运行中）"不使用中途 epoch 指标。

| 任务 | Backbone | 固定 v3_setting | 原 v3：学习式三证据校准 | 三证据直接平均 | w/o Semantic | w/o Overlap |
|---|---|---|---|---|---|---|
| Cloth→Sport | EMCDR | broad | 0.0182 / 0.0182 | 0.0185 / 0.0180 | **0.0197 / 0.0181** | 0.0186 / 0.0180 |
| Cloth→Sport | UniCDR | broad | 0.0512 / 0.0458 | —（运行中） | —（运行中） | —（运行中） |
| Cloth→Sport | CD-CDR Normal | broad | **0.0221 / 0.0217** | 0.0213 / 0.0214 | 0.0217 / 0.0215 | 0.0217 / 0.0215 |
| Cloth→Sport | CDRIB | balanced | **0.0252** / 0.0200 | 0.0214 / **0.0201** | 0.0195 / 0.0190 | 0.0207 / 0.0182 |
| Phone→Elec | EMCDR | strict | 0.0409 / 0.0475 | 0.0409 / 0.0475 | 0.0409 / 0.0475 | 0.0409 / 0.0475 |
| Phone→Elec | UniCDR | balanced | 0.0589 / 0.0672 | —（运行中） | —（运行中） | —（运行中） |
| Phone→Elec | CD-CDR Normal | strict | 0.0336 / 0.0390 | 0.0336 / 0.0390 | 0.0336 / 0.0390 | 0.0336 / 0.0390 |
| Phone→Elec | CDRIB | broad | 0.0452 / 0.0521 | —（运行中） | —（运行中） | —（运行中） |

### 消融定义

- **原 v3**：使用正权线性校准器联合学习 `c_sem`、`c_ov` 和 `c_model`。
- **三证据直接平均**：不训练校准函数，直接计算 `(c_sem + c_ov + c_model) / 3`。
- **w/o Semantic**：去掉 `c_sem`，校准器只学习 `c_ov + c_model`。
- **w/o Overlap**：去掉 `c_ov`，校准器只学习 `c_sem + c_model`。
- 当前已完成 **5/8** 行；Cloth→Sport UniCDR、Phone→Elec UniCDR 和 Phone→Elec CDRIB 仍在运行，完成后回填最终测试结果。
- 已完成结果中，EMCDR Cloth→Sport 的 w/o Semantic 提高 Recall 但未超过原 v3 的 NDCG；CD-CDR Normal 与 CDRIB Cloth→Sport 的原学习式三证据校准整体更稳。Phone→Elec 的 EMCDR 与 CD-CDR Normal 对三种消融均不敏感。

## Douban Book→Music（已完成）

本节记录当前代码下 Douban Book→Music 的新一轮实验。数值统一为 **R@20 / N@20**。四个 Pure Backbone 和四个阶段 2 v2.1 搜索均已完成，每个 v2.1 结果均从 12 组 `adaptive_setting` 中选出。

| Backbone | Pure Backbone | 阶段 2 v2.1（Adaptive） | 最佳 adaptive_setting |
|---|---|---|---|
| EMCDR | 0.0217 / 0.0914 | 0.0217 / 0.0860 (+0.0000 / -0.0054) | j1_b0 |
| UniCDR | 0.0248 / 0.0882 | 0.0237 / 0.0880 (-0.0011 / -0.0002) | j025_b001 |
| CD-CDR Normal（修正版） | 0.0262 / 0.0880 | 0.0188 / 0.0760 (-0.0074 / -0.0120) | j1_b0005 |

| Backbone | Pure Backbone | 阶段 2 v2.1（Adaptive） | 最佳 adaptive_setting |
|---|---|---|---|
| CDRIB | 0.0220 / 0.0875 | **0.0229 / 0.0890** (+0.0009 / +0.0015) | j05_b003 |

### 当前观察

- 四个阶段 2 v2.1 搜索均完成 12/12，日志中未发现报错、OOM 或进程异常退出。
- CDRIB 实现严格双升；EMCDR 的 Recall 持平但 NDCG 下降；UniCDR 小幅双降；CD-CDR Normal 双降且降幅最大。
- Book→Music 上阶段 2 v2.1 的严格双升覆盖为 **1/4**，均不下降覆盖为 **1/4**。当前插件配置在该任务上的跨 Backbone 泛化仍不稳定。

## 覆盖情况

| 插件变体 | 严格双升 | 均不下降 |
|---|---|---|
| 原始物品级 G | 3 / 8 | 5 / 8 |
| 用户级 G | 2 / 8 | 3 / 8 |
| Direct Semantic | 3 / 8 | 4 / 8 |
| Popularity | 3 / 8 | 3 / 8 |
| 阶段 2 v1 | 3 / 8 | 3 / 8 |
| 阶段 2 v2 | 3 / 8 | 5 / 8 |
| 阶段 2 v2.1 | 6 / 8 | 8 / 8 |
| 阶段 3（新版 v3） | 7 / 8 | 8 / 8 |

## 当前观察

- 阶段 2 v2.1 已完成 8/8：其中 6 组严格双升，8 组均不下降。
- 新版 v3 相对 Pure Backbone 达到 7/8 严格双升、8/8 均不下降，严格双升覆盖由 v2.1 的 6/8 提高到 7/8。
- 直接与 v2.1 比较时，新版 v3 仅在 CD-CDR Normal Cloth→Sport 和 UniCDR Phone→Elec 上实现双升；EMCDR Phone→Elec 与 CD-CDR Normal Phone→Elec 持平，CDRIB 两个方向均明显下降。
- 阶段 2 v2 修复了 Cloth→Sport 上 UniCDR 在阶段 2 v1 中的明显退化，并达到 +0.0002 / +0.0007；但它在 Phone→Elec 上的泛化仍不稳定。
- CDRIB 对伪监督最敏感。阶段 2 v1 在 Phone→Elec 上达到 0.0512 / 0.0550，相对纯 Backbone 提升 +0.0128 / +0.0073。
- 修正版 CD-CDR Normal 在两个任务上均出现多个严格双升插件：Cloth→Sport 以阶段 2 v2.1 的 0.0213 / 0.0214 最优；Phone→Elec 以 Popularity 的 0.0411 / 0.0437 最优，用户级 G 的 0.0408 / 0.0417 次之。
- 当前仍未达到全部 8 个“任务 × Backbone”严格双升；唯一未严格双升的是 EMCDR Cloth→Sport，其 N@20 与 Pure Backbone 持平。