伪交互质量是否真的影响推荐性能

为什么伪监督通常会提升推荐效果

核心问题

当前要验证的不是“模型是否提升”，而是要拆清楚性能提升到底来自哪里：

1. 伪监督是否真的让冷启动用户参与了跨域迁移函数学习；
2. 伪监督质量是否会影响推荐性能；
3. 扩散模型是否只是作为更强的迁移 backbone，本身就能带来提升；
4. 当前伪监督迁移损失权重很小，是否导致伪监督实际上几乎没有被模型利用。

关键怀疑：如果伪监督对应的迁移损失权重非常小，那么性能提升很可能不是来自伪监督，而是来自扩散模型建立了更好的跨域迁移关系。

当前主线

文章主线仍然是：如何让目标域无交互的冷启动用户参与跨域迁移函数学习。

但现在的挑战需要从“如何构造伪交互”调整为：

- 如何判断伪监督是否可靠；
- 如何利用可靠伪监督；
- 以及更基础地，伪监督本身到底有没有提供有效训练信号。

因此接下来实验的目标不是证明某个方法最好，而是诊断：伪监督机制是否真的成立。

伪监督三类/四类划分

1. Exact-hit pseudo supervision

含义：伪监督直接来自冷启动用户真实目标域交互。

作用：作为 oracle upper bound。

预期：如果训练框架能利用伪监督，它应该显著优于 overlap-only。若 exact-hit 都不提升，说明当前伪监督训练机制可能无效。

2. Preference-neighbor pseudo supervision

含义：伪监督没有命中真实目标交互，但位于真实目标偏好的邻域。

构造方式：

- 先用目标域 warm users 训练 item embedding；
- 对每个冷启动用户的真实目标正样本找 Top-K 近邻；
- 排除该用户真实交互物品；
- 将这些近邻作为未命中但偏好相近的伪监督。

作用：验证“完全没命中不代表无用”。

预期：如果弱伪监督有价值，它应该高于 random 或 inconsistent，甚至可能高于 overlap-only。

3. Random pseudo supervision

含义：从目标域随机采样物品作为伪监督。

作用：判断伪监督是否只是提供了一个训练入口，而不依赖具体偏好质量。

预期：通常不应接近 exact-hit。若 random 与 exact-hit 接近，说明模型可能没有真正利用 item-level 伪监督质量。

4. Preference-inconsistent pseudo supervision

含义：选择与用户真实目标偏好尽可能远的物品作为伪监督。

构造方式：

- 在目标域 item embedding 空间中选择远离真实目标正样本的 Bottom-K / farthest items；
- 或选择跨类别、低相似度的物品。

作用：验证错误伪监督是否有害。

预期：如果伪监督真的参与训练，inconsistent 应该伤害性能，甚至低于 overlap-only。

必须加入的关键基线

Overlap-only

只使用源域和目标域都有交互的重叠用户训练迁移函数，不让冷启动用户通过伪监督参与训练。

这是最重要的对照，因为原始问题就是：冷启动用户无法参与迁移函数训练。

四类伪监督必须和 overlap-only 比，而不是只在彼此之间比较。

核心实验 1：伪监督质量诊断表

在同一个 backbone 上比较以下设置：

Setting	冷启动用户是否参与训练	伪监督类型	目的
Overlap-only	否	无	原始跨域迁移基线
Exact-hit	是	真实目标交互	伪监督上限
Preference-neighbor	是	近邻但不命中	验证弱伪监督价值
Random	是	随机目标物品	验证随机伪监督是否也有效
Inconsistent	是	远邻/反偏好物品	验证错误伪监督是否有害

理想趋势：

Exact-hit > Preference-neighbor > Random > Inconsistent

但更关键的是：

- Exact-hit 是否明显高于 Overlap-only；
- Preference-neighbor 是否高于 Random；
- Inconsistent 是否低于 Overlap-only；
- Random 是否异常接近 Exact-hit。

核心实验 3：伪监督损失权重扫描

扫描伪监督迁移损失权重：

lambda_pseudo ∈ {0, 1e-4, 1e-3, 1e-2, 1e-1, 1}

对至少三类伪监督跑：

- Exact-hit；
- Random；

- Inconsistent。

重点观察：

现象	解释
Exact-hit 随 lambda 增大而提升	模型确实能利用高质量伪监督
Inconsistent 随 lambda 增大而下降	错误伪监督会污染迁移函数
Random 基本不变	随机伪监督训练价值有限
所有类型都差不多	伪监督可能没有被真正利用，backbone 主导

这个实验尤其重要，因为当前伪监督权重很小，可能导致冷启动用户只是“名义参与”，没有产生实质训练贡献。

核心实验 4：换弱 backbone

目的：判断 diffusion 是否过强，从而掩盖伪监督质量差异。

建议至少比较两档 backbone：

Backbone	能力	目的
Weak Transfer：Linear / MLP mapping	弱	看伪监督本身是否提供直接监督增益
Diffusion Transfer	强	看 diffusion 是否替代或放大伪监督作用

每个 backbone 上跑：

- Overlap-only；
- Exact-hit；
- Preference-neighbor；
- Random；
- Inconsistent

需要回答的四个诊断问题

Q1：Oracle 伪监督有没有用？

看 Exact-hit 是否显著超过 Overlap-only。

若否，说明当前训练框架不能有效利用伪监督。

Q2：非命中但相近的伪监督有没有用？

看 Preference-neighbor 是否超过 Random / Overlap-only。

若否，说明“未命中但偏好相近”的价值有限。

Q3：错误伪监督是否有害？

看 Inconsistent 是否低于 Overlap-only。

若否，说明模型可能没有真正吃进去伪监督，或者伪监督权重太小。

Q4：扩散 backbone 是否独立贡献主要收益？

看 weak backbone 和扩散backbone的性能差别

若是，说明主要贡献来自 diffusion 架构，而不是伪监督。

最小优先级实验计划

Step 1：单数据集最小闭环

先在一个代表性数据集上跑：

1. Overlap-only；
2. Diffusion lambda = 0；
3. Diffusion + Exact-hit；
4. Diffusion + Preference-neighbor；
5. Diffusion + Random；
6. Diffusion + Inconsistent。

目的：快速判断伪监督和 diffusion 的贡献边界。

Step 2：lambda 扫描

对 Exact-hit / Random / Inconsistent 跑：

lambda_pseudo ∈ {0, 1e-4, 1e-3, 1e-2, 1e-1, 1}

目的：判断当前小权重是否导致伪监督无效。

Step 3：弱 backbone 对照

用 Linear / MLP mapping 跑：

- Overlap-only；
- Exact-hit；
- Neighbor；
- Random；
- Inconsistent。

目的：判断伪监督质量差异是否在弱模型上更明显。

Step 4：扩展到多个数据集

只有当 Step 1–3 结果支持伪监督方向时，再扩展到多个数据集和完整指标。