# CDR 单点可信自演化伪监督：Grounded and Expandable Pseudo-Supervision (投TOIS)

## 1. 问题与核心思想

目标域冷启动用户缺乏真实交互，CDR backbone 因而只能依赖少量重叠用户学习跨域迁移。直接引入伪监督可以扩展监督覆盖，但随之出现两个新的核心问题：其一，初始伪监督缺乏真实目标域反馈校验，容易把错误迁移知识注入 backbone；其二，若训练始终局限在初始候选集合，模型后续学到的新协同知识无法发现初始阶段遗漏的目标物品，伪监督会被锁定在初始 support 中。

因此，本工作不把伪监督视为一次性生成的固定标签，而将其建模为一个**可校准、可扩展的监督状态**：先利用源域语义知识形成初始目标域候选，再用少量真实跨域行为与当前模型知识共同校准候选可信度，最后利用 backbone 新学到的协同规律扩展候选 support，并对新增监督重新验证。

整体过程为：

$$\text{Semantic Initialization} \rightarrow \text{Behavioral Grounding} \rightarrow \text{Confidence-weighted Learning} \rightarrow \text{Collaborative Expansi}$$

模块最终只向任意 CDR backbone 提供：

$$\mathcal{S}_u^{(r)} = \{(i, \rho_{ui}^{(r)})\},$$

即当前阶段可用于训练的目标物品及对应可信权重。

## 2. Semantic-to-Collaborative Supervision Initialization

### 2.1 面向目标物品属性的跨域兴趣迁移

对于目标域冷启动用户 $u$，仅有源域行为 $\mathcal{I}_u^s$。大语言模型首先从其源域交互、评论和物品属性中抽取多个潜在目标域兴趣：

$$\mathcal{I}_u^s \rightarrow \{q_{u1}^t, \ldots, q_{uM}^t\}.$$

关键不在于生成抽象的“用户兴趣标签”，而是把每个兴趣统一表述为**什么样属性的目标域物品可能吸引该用户**。例如，在电影域中，可表述为“具有严谨科学设定、宇宙探索主题和复杂世界观的电影”。

同时，对目标域物品采用相同语义描述范式得到物品语义表示 $s_i^t$。这样，用户跨域兴趣和目标物品被对齐到统一的目标物品属性语义空间。

该阶段离线执行一次并缓存，LLM 不参与后续在线迭代。

### 2.2 独立目标域协同空间与语义—协同桥接

语义相关并不等价于真实用户行为中的协同偏好。因此，本工作在目标域已有普通用户交互上单独训练轻量协同编码器，得到目标物品协同表示：

$$e_i^t.$$

该表示独立于具体 CDR backbone，可由 MF、LightGCN 等常规 target-domain encoder 学得。于是每个目标物品天然形成一对：

$$(s_i^t, e_i^t).$$

利用这些目标域内部配对关系学习语义—协同桥接函数：

$$G_t : s_i^t \rightarrow e_i^t.$$

对于冷启动用户第 $m$ 个目标域语义兴趣，得到初始协同偏好原型：

$$p_{um} = G_t(q_{um}^t).$$

结合不同兴趣在源域行为中的覆盖强度 $w_{um}$，得到初始目标物品匹配分数：

$$c_{ui}^{sem} = \sum_{m} w_{um} \, \mathrm{sim}\big(p_{um}, e_i^t\big) \, .$$

并从完整目标物品空间中检索初始候选：

$$\mathcal{C}_u^{sem} = \mathrm{TopK}_s(c_{ui}^{sem}).$$

由此完成从“源域行为中的潜在语义兴趣”到“目标域协同候选监督”的初始化。

## 3. Grounded Multi-Evidence Reliability Estimation（直接用大语言模型得到置信度）

初始候选仍然只是跨域推断结果，其可靠性需要额外真实证据进行校准。本工作利用三类互补信号刻画每个候选 $(u, i)$ 的可信程度。

### 3.1 源域迁移支持

保留初始化阶段对候选的跨域支持强度，记为：

$$c_{ui}^{sem}.$$

它描述源域语义兴趣经目标协同桥接后对候选物品的支持程度。

### 3.2 相似重叠用户的真实目标域行为支持

为冷启动用户单独训练或复用一个 source-only 行为编码器 (结合前面的相当于一开始分别在源域和目标域训练一个互相独立的encoder模型)，根据源域交互得到：

$$h_u^s.$$

仅依据源域行为，在重叠用户集合 $\mathcal{U}^o$ 中寻找源域兴趣相似邻居：

$$\mathcal{N}_u^o = \mathrm{TopN}_{v \in \mathcal{U}^o} \mathrm{sim}(h_u^s, h_v^s).$$

这些邻居具有真实目标域行为 $\mathcal{I}_v^t$。因此，可利用其真实交互对候选 $i$ 提供行为 grounding：

$$c_{ui}^{ov} = \sum_{v \in \mathcal{N}_u^o} \bar{a}_{uv} \max_{j \in \mathcal{I}_v^t} \mathrm{sim}(e_i^t, e_j^t),$$

其中 $\bar{a}_{uv}$ 为基于源域相似度归一化后的邻居权重。

该信号刻画的是：**与冷启动用户具有相似源域兴趣的人，在目标域中的真实选择是否支持该候选。** 少量重叠用户因此从“主要迁移监督来源”转变为“真实跨域行为锚点”。

### 3.3 当前 CDR backbone 的动态协同支持

随着训练推进，CDR backbone 会逐渐学到新的跨域协同知识。记当前 backbone 为 $f_{\theta^{(r)}}$，并维护 EMA teacher：

$$\bar{\theta}^{(r)} \leftarrow \mu \bar{\theta}^{(r-1)} + (1-\mu)\theta^{(r)}.$$

由稳定 teacher 给出当前候选的动态模型支持：

$$c_{ui}^{model,(r)} = f_{\bar{\theta}^{(r)}}(u, i).$$

它反映当前已经学到的跨域迁移规律是否继续支持这条伪监督。

## 4. Lightweight Reliability Calibration

对每个候选构造证据向量：

$$x_{ui}^{(r)} = [c_{ui}^{sem}, c_{ui}^{ov}, c_{ui}^{model,(r)}].$$

可信度不由复杂高容量网络学习，而通过一个低容量校准器得到：

$$\rho_{ui}^{(r)} = \sigma\Big(\beta_0 + \beta_1 c_{ui}^{sem} + \beta_2 c_{ui}^{ov} + \beta_3 c_{ui}^{model,(r)}\Big).$$

少量重叠用户仅用于学习少数全局校准参数 $\beta$。具体地，将部分重叠用户模拟为冷启动用户，仅使用其源域行为生成候选，再利用其隐藏的真实目标交互对校准器进行监督。

这里学习的不是高维 source-to-target preference mapping，而是不同证据与监督可靠性之间的低容量映射。因而 supervision generation 仍由语义迁移和目标域协同桥承担，重叠用户只提供 sparse real grounding 与全局 calibration。

经过校准，得到当前有效伪监督状态：

$$\mathcal{S}_u^{(r)} = \{(i, \rho_{ui}^{(r)}) \mid i \in \mathcal{C}_u^{(r)}, \rho_{ui}^{(r)} > \tau\}.$$

## 5. Confidence-Weighted Plug-in Learning

该模块不要求修改 CDR backbone 的内部结构，只需将当前伪监督及其权重注入原训练目标：

$$\mathcal{L} = \mathcal{L}_{CDR} + \lambda \sum_{u} \sum_{(i,\rho_{ui}) \in \mathcal{S}_u^{(r)}} \rho_{ui}\, \ell_{pseudo}(u, i).$$

因此，任意能输出用户—物品预测分数并接受样本权重的 CDR 方法都可以直接接入该插件。

## 6. Collaborative Support Expansion

如果后续训练始终局限于初始候选 $\mathcal{C}_u^{(0)}$，那么任何未在初始化阶段被召回的真实目标偏好都无法进入伪监督集合。为突破这一 support locking，本工作让新学到的协同知识主动参与候选扩展。

训练若干阶段后，EMA backbone 已经从真实 overlap supervision 和高可信伪监督中获得新的跨域模式。利用 teacher 在完整目标物品空间中重新检索：

$$\mathcal{E}_u^{(r)} = \mathrm{TopK}_e\left(f_{\tilde{\theta}^{(r)}}(u, i), i \in \mathcal{I}^t\right).$$

其中 $\mathcal{E}_u^{(r)}$ 表示当前模型新发现的候选目标物品。该过程只依赖轻量 backbone scoring，不重新调用 LLM。

## 7. Anchored Re-proposal and Re-grounding

下一阶段候选集合由三部分共同组成：

$$\mathcal{C}_u^{(r+1)} = \mathcal{C}_u^{sem} \cup \mathcal{S}_u^{(r)} \cup \mathcal{E}_u^{(r)},$$

其中：

- $\mathcal{C}_u^{sem}$：初始语义—协同候选，作为稳定语义锚点；
- $\mathcal{S}_u^{(r)}$：上一阶段高可信监督；
- $\mathcal{E}_u^{(r)}$：当前 backbone 从全体目标物品空间中新发现的协同候选。

所有新增候选必须重新经过真实行为 grounding 和 reliability calibration，得到新的：

$$\rho_{ui}^{(r+1)}.$$

于是模型负责**探索新的监督 support**，Verifier 负责**判断新监督是否值得进入训练状态**。

## 8. 完整自演化流程

整个训练过程形成：

$$\text{Source Behavior} \xrightarrow{\text{LLM} + G_t} \mathcal{C}^{(0)} \xrightarrow{\text{Grounding}} \mathcal{S}^{(0)} \xrightarrow{\text{Weighted CDR}} \theta^{(1)} \xrightarrow{\text{Collaborative Exploration}} \mathcal{C}^{(1)} \xrightarrow{\text{Re-grounding}} \mathcal{S}^{(1)} \rightarrow \cdots$$

从监督状态角度看，该过程完成三个连续动作：

$$\boxed{\text{Initialize} \rightarrow \text{Ground} \rightarrow \text{Expand}}$$

即：

1. **Semantic Initialization**：利用源域语义知识和目标域协同结构形成第一批候选监督；
2. **Behavioral Grounding**：利用真实重叠用户行为和当前模型知识校准监督可信度；
3. **Collaborative Expansion**：利用新学到的跨域协同规律主动发现初始阶段遗漏的监督，并重新校准。

## 9. 方法核心

本工作把冷启动伪监督从一次性固定标签改造成一个**grounded and expandable pseudo-supervision state**：初始语义知识负责打开目标域监督空间，少量真实双域行为负责校准其可信程度，而 CDR backbone 新学到的协同知识进一步扩展该监督空间。

**个人认为的创新点：1.G  2. 多证据(尤其是第二类) 3.overlap-grounded 4.expand set**

因此，方法直接对应冷启动 CDR 中三个连续问题：

$$\text{监督从哪里来} \rightarrow \text{哪些监督可信} \rightarrow \text{如何发现初始阶段遗漏的监督.}$$

技术路线则形成统一闭环：

$$\boxed{\text{Semantic Prior} \rightarrow \text{Grounded Supervision} \rightarrow \text{Collaborative Knowledge} \rightarrow \text{Expanded Supervision}}$$

以上作为TOIS改进版本:

\rho分三类等级是不是还可以做，\rho如何加入训练是不是还能继续研究(课程学习)

**第一类证据和第二类证据的构建依赖协同表征，这个要更新吗，如果不更新就是fix的，那为何还要第一类证据先构建伪交互集合，第二类证据再判断可信度啊？**

不更新 源域训练一个 目标域训练一个冻结表征又能咋样，反正fix住跟后文又没关系. 第二类证据是有overlap ground作为背书的, 第一类证据没有